

Kalman Filters: From Linear to Nonlinear Systems

Minsu Kim

2026.07.02

Contents

- Introduction
- Kalman Filter
 - Linear system
 - Non-linear system
 - IKF(IESKF)
 - Lie group, algebra

Introduction

- 어쩌다... Kalman Filter를...
 - Robotics에서 안쓰이는 곳이 드물 정도..
 - State Estimation을 한다 하면 기본이 되는 이론
 - SLAM에서 꼭 필요한 방식이기 때문에 준비해봤습니다 😊
 - 이전의 R3LIVE의 FAST-LIO2를 알기 위해서는 Kalman Filter가 그 시작점..!
- SLAM 분야에서는, Filter based method가 한때 유행했었음
 - Probabilistic Robotics 책에서 소개하는 EKF-SLAM이 대표적
 - 그러다, Why Filter? 라는 논문의 등장으로 Keyframe-based optimization이 SLAM 분야의 주류가 됨
 - 개인적으로 이 방식의 정점을 찍은 논문이 GTSAM factor graph를 사용한 LIO-SAM(IROS, 2020)이라고 생각
 - 다시 2021년, FAST-LIO의 등장으로 optimization과 비슷한 IKF를 사용한 filter-based 방식이 재등장
 - 드론에 써야하다보니 속도가 중요함. 정확도는 IKF에서!

Kalman Filter - Linear System

- Kalman Filter의 대표적인 가정 3가지
 - Gaussian noise assumption: 시스템의 노이즈는 가우시안 분포를 따른다고 가정

$$p(\mathbf{x}) = \det(2\pi\Sigma)^{-\frac{1}{2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\}$$

- Markov assumption: 시스템의 상태는 바로 직전 상태에만 의존한다고 가정



$$p(\mathbf{x}_t) = p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_t)$$

- Linear system이라고 가정

$$\mathbf{x}_t = \mathbf{A}\mathbf{x}_{t-1} + \mathbf{B}\mathbf{u}_t + \epsilon_t$$

Kalman Filter - Linear System

- 그림으로 보면 어떻게 되나요?



Kalman Filter - Linear System

- $\mathbf{x}_t$ 는 state vector, $\mathbf{u}_t$ 는 control input, $\epsilon_t \sim \mathcal{N}(0, R)$ 는 noise

$$\mathbf{x}_t = \begin{pmatrix} x_{1,t} \\ x_{2,t} \\ \vdots \\ x_{n,t} \end{pmatrix} \quad \text{and} \quad \mathbf{u}_t = \begin{pmatrix} u_{1,t} \\ u_{2,t} \\ \vdots \\ u_{m,t} \end{pmatrix}$$

- 그렇다면, 선형변환일 때의 평균과 공분산이 어떻게 이동하는지 수학으로 알아봅시다


Kalman Filter - Linear System

도대체 넌 왜 why..

- 단변수일 때 평균, 편차, 분산 😊

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\Delta x_i = x_i - \mu$$

$$V = \frac{1}{n} \sum_{i=1}^n \Delta x_i \Delta x_i^\top = \frac{1}{n} \sum_{i=1}^n (\Delta x_i)^2$$

- 다변수일 때의 평균과 공분산 🤖

$$\mathbf{x}_i = \begin{pmatrix} x_i \\ y_i \end{pmatrix}, \quad \boldsymbol{\mu} = \begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \quad \Delta \mathbf{x}_i = \mathbf{x}_i - \boldsymbol{\mu}$$

$$\boldsymbol{\Sigma} = \frac{1}{n} \sum_{i=1}^n \Delta \mathbf{x}_i \Delta \mathbf{x}_i^\top$$

$$\Delta \mathbf{x}_i \Delta \mathbf{x}_i^\top = \begin{pmatrix} \Delta x_i \\ \Delta y_i \end{pmatrix} \begin{pmatrix} \Delta x_i & \Delta y_i \end{pmatrix} = \begin{bmatrix} \Delta x_i^2 & \Delta x_i \Delta y_i \\ \Delta x_i \Delta y_i & \Delta y_i^2 \end{bmatrix}$$

Kalman Filter - Linear System

◦ 평균 이동

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$$

$$\boldsymbol{\mu}_y = \frac{1}{n} \sum_{i=1}^n \mathbf{y}_i = \frac{1}{n} \sum_{i=1}^n (\mathbf{A}\mathbf{x}_i + \mathbf{b})$$

$$\rightarrow \mathbf{A} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \right) + \mathbf{b} = \mathbf{A}\boldsymbol{\mu}_x + \mathbf{b}$$

$$\therefore \boldsymbol{\mu}_y = \mathbf{A}\boldsymbol{\mu}_x + \mathbf{b}$$

◦ 공분산 이동

$$\boldsymbol{\Sigma}_y = \frac{1}{n} \sum_{i=1}^n (\mathbf{y}_i - \boldsymbol{\mu}_y)(\mathbf{y}_i - \boldsymbol{\mu}_y)^\top$$

$$\frac{1}{n} \sum_{i=1}^n [(\mathbf{A}\mathbf{x}_i + \mathbf{b}) - (\mathbf{A}\boldsymbol{\mu}_x + \mathbf{b})][(\mathbf{A}\mathbf{x}_i + \mathbf{b}) - (\mathbf{A}\boldsymbol{\mu}_x + \mathbf{b})]^\top$$

$$= \frac{1}{n} \sum_{i=1}^n \mathbf{A}(\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^\top \mathbf{A}^\top$$

$$= \mathbf{A} \left(\frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^\top \right) \mathbf{A}^\top = \mathbf{A} \boldsymbol{\Sigma} \mathbf{A}^\top$$

$$\therefore \boldsymbol{\Sigma}_y = \mathbf{A} \boldsymbol{\Sigma} \mathbf{A}^\top$$

Kalman Filter - Prediction step

- 그래서,, previous state와 control input만 가지고 prediction을 해보면
 - 그리고, state에 대해서 **정확히** 알고있다고 가정하면,

$$\mathbf{x}_{t-1} \sim \mathcal{N}(\boldsymbol{\mu}_{t-1}, \mathbf{0})$$

- 정확한 이전 state를 기준으로 선형변환이 가해진다고 가정하면, 선형변환된 **평균**을 알 수 있음

$$\bar{\boldsymbol{\mu}}_{\mathbf{x}_t} = \mathbf{A}_t \boldsymbol{\mu}_{t-1} + \mathbf{B}_t \mathbf{u}_t$$

- 여기에, motion/process noise를 고려하면, 다음과 같이 **공분산** 계산가능

$$\boldsymbol{\epsilon}_t \sim \mathcal{N}(0, \mathbf{R}), \quad \bar{\boldsymbol{\Sigma}}_{\mathbf{x}_t} = \mathbf{A}_t \mathbf{0} \mathbf{A}_t^\top + \mathbf{R} = \mathbf{R}$$

- 따라서, 다음 state $\mathbf{x}_t$ 는 선형변환된 평균과 motion/process noise를 반영하여 표현 가능

$$\mathbf{x}_t = \bar{\boldsymbol{\mu}}_{\mathbf{x}_t} + \boldsymbol{\epsilon}_t = \mathbf{A}_t \mathbf{x}_{t-1} + \mathbf{B}_t \mathbf{u}_t + \boldsymbol{\epsilon}_t$$

Kalman Filter - Prediction step

- 또 다르게 써보면

$$\mathbf{x}_t \sim \mathcal{N}(\bar{\mu}_{\mathbf{x}_t}, \bar{\Sigma}_{\mathbf{x}_t})$$

- 확률관점에서 정리해보면, 다음 state는 prediction mean 주변에 있을 가능성이 가장 높고, 그 불확실성은 covariance로 표현

$$p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_t) = \eta \exp \left\{ -\frac{1}{2} (\mathbf{x}_t - (\mathbf{A}_t \mathbf{x}_{t-1} + \mathbf{B}_t \mathbf{u}_t))^{\top} \mathbf{R}^{-1} (\mathbf{x}_t - (\mathbf{A}_t \mathbf{x}_{t-1} + \mathbf{B}_t \mathbf{u}_t)) \right\}$$

$$p(\mathbf{x}_t) \triangleq p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_t) = \eta \exp \left\{ -\frac{1}{2} (\mathbf{x}_t - \bar{\mu}_{x_t})^{\top} \bar{\Sigma}_{x_t}^{-1} (\mathbf{x}_t - \bar{\mu}_{x_t}) \right\}$$

Kalman Filter - Correction step

- Prediction step 에서 예측된 state는 단순 motion model(control input)에 의해서만 계산된 state
 - 따지고 보면 눈 감고 1m가라! 한 것과 마찬가지로
 - 불확실성이 클 수 밖에 없음
- 따라서, 실제 관측값을 이용해서 **예측된 state**를 **보정**해주는 과정이 필요함
 - 또는 여러 후보 state중, 가장 정확한 state를 찾아내는 과정 이라고 해도 무방함
- 이 과정을 **Correction step**이라고 하고, 실제 관측값과 예측된 관측값의 차이 (residual)를 이용하여 state를 update
- 위 두 과정을 거친 state를 Final state라고 할게요 😊

Kalman Filter - Correction step

- Measurement model

$$\mathbf{z}_t = \mathbf{C}_t \mathbf{x}_t + \boldsymbol{\delta}_t, \quad \boldsymbol{\delta}_t \sim \mathcal{N}(0, \mathbf{Q})$$

- 예측한 state를 기준으로 관측한 값은 아래와 같이 표현

$$\bar{\mathbf{z}}_t = \mathbf{C}_t \bar{\boldsymbol{\mu}}_{\mathbf{x}_t}$$

- 따라서, 실제 관측값과 예측된 관측값의 차이인 residual과 센서의 노이즈를 고려하면, 아래와 같이 표현 가능

$$p(\mathbf{z}_t | \mathbf{x}_t) = \eta \exp \left\{ -\frac{1}{2} (\mathbf{z}_t - \mathbf{C}_t \bar{\boldsymbol{\mu}}_{\mathbf{x}_t})^\top \mathbf{Q}^{-1} (\mathbf{z}_t - \mathbf{C}_t \bar{\boldsymbol{\mu}}_{\mathbf{x}_t}) \right\}$$

Kalman Filter - Bayes' Rule

- 그렇다면, 이제 Kalman Gain을 구해서 update를 해주면 되는데, 이 때 Bayes rule을 잠깐 사용

- Bayes' rule: $p(A|B) = \frac{p(B|A)p(A)}{p(B)} = p(A|B) = \frac{\text{likelihood} \times \text{prior}}{\text{evidence}}$

- 이 결과를 이용하여, Bayes rule에 의해 지수부분을 합으로 표현

$$p(\mathbf{x}_t | \mathbf{z}_t) = \eta p(\mathbf{z}_t | \mathbf{x}_t) p(\mathbf{x}_t)$$

$$\rightarrow \exp\left(-\frac{1}{2} \text{likelihood}\right) \times \exp\left(-\frac{1}{2} \text{prior}\right) \rightarrow \exp\left(-\frac{1}{2} (\text{likelihood} + \text{prior})\right)$$

- exponential term, normalization term 제외하고 보면

$$\mathbf{G}(\mathbf{x}_t) = ((\mathbf{z}_t - \mathbf{C}_t \mathbf{x}_t)^\top \mathbf{Q}^{-1} (\mathbf{z}_t - \mathbf{C}_t \mathbf{x}_t) + (\mathbf{x}_t - \bar{\boldsymbol{\mu}}_{x_t})^\top \bar{\boldsymbol{\Sigma}}_{x_t}^{-1} (\mathbf{x}_t - \bar{\boldsymbol{\mu}}_{x_t}))$$

Kalman Filter - Maximum A Posteriori (MAP)

- 전개해봅시다

$$\begin{aligned} \mathbf{G}(\mathbf{x}_t) &= \left(\mathbf{x}_t^\top \bar{\Sigma}_{x_t}^{-1} \mathbf{x}_t - 2\bar{\boldsymbol{\mu}}_{x_t}^\top \bar{\Sigma}_{x_t}^{-1} \mathbf{x}_t + \bar{\boldsymbol{\mu}}_{x_t}^\top \bar{\Sigma}_{x_t}^{-1} \bar{\boldsymbol{\mu}}_{x_t} + \mathbf{z}_t^\top \mathbf{Q}^{-1} \mathbf{z}_t - 2\mathbf{z}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t \mathbf{x}_t + \mathbf{x}_t^\top \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t \mathbf{x}_t \right) \\ &= \left(\mathbf{x}_t^\top (\bar{\Sigma}_{x_t}^{-1} + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t) \mathbf{x}_t - 2\bar{\boldsymbol{\mu}}_{x_t}^\top \bar{\Sigma}_{x_t}^{-1} \mathbf{x}_t - 2\mathbf{z}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t \mathbf{x}_t + \text{const} \right) \end{aligned}$$

- 여기서 제일정확한 $\mathbf{x}_t$ 는 $\mathbf{G}(\mathbf{x}_t)$ 가 최대가 되는 지점 $\rightarrow$ MAP! 를 구하면 됨

$$\frac{\partial \mathbf{G}(\mathbf{x}_t)}{\partial \mathbf{x}_t} = \bar{\Sigma}_{x_t}^{-1} (\mathbf{x}_t - \bar{\boldsymbol{\mu}}_{x_t}) - 2\mathbf{C}_t^\top \mathbf{Q}^{-1} (\mathbf{z}_t - \mathbf{C}_t \mathbf{x}_t) = 0$$

$$\frac{\partial \mathbf{x}^\top \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = 2\mathbf{A} \mathbf{x}, \quad \frac{\partial \mathbf{x}^\top \mathbf{b}}{\partial \mathbf{x}} = \mathbf{b}$$

Kalman Filter - Kalman Gain derivation

- 앞서 본 간단한 미분법칙을 이용하면, 아래와 같이 정리 가능

$$2(\bar{\Sigma}_{x_t}^{-1} + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t) \mathbf{x}_t - 2\bar{\mu}_{x_t}^\top \bar{\Sigma}_{x_t}^{-1} - 2\mathbf{z}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t = 0$$

$$\rightarrow (\bar{\Sigma}_{x_t}^{-1} + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t) \mathbf{x}_t - \bar{\mu}_{x_t}^\top \bar{\Sigma}_{x_t}^{-1} - \mathbf{z}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t = 0$$

$$\rightarrow (\bar{\Sigma}_{x_t}^{-1} + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t) \mathbf{x}_t - \bar{\Sigma}_{x_t}^{-1} \bar{\mu}_{x_t} - \mathbf{Q}^{-1} \mathbf{C}_t \mathbf{z}_t = 0$$

$$\rightarrow \bar{\Sigma}_{x_t}^{-1} \mathbf{x}_t + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t \mathbf{x}_t - \bar{\Sigma}_{x_t}^{-1} \bar{\mu}_{x_t} - \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{z}_t = 0$$

$$\rightarrow \bar{\Sigma}_{x_t}^{-1} (\mathbf{x}_t - \bar{\mu}_{x_t}) - \mathbf{C}_t^\top \mathbf{Q}^{-1} (\mathbf{z}_t - \mathbf{C}_t \mathbf{x}_t) = 0$$

Kalman Filter - Kalman Gain derivation

- 여기서 correction을 위해서 residual을 predicted mean을 가지고 다시정리해보면,

$$\mathbf{z}_t - \mathbf{C}_t \mathbf{x}_t = \mathbf{z}_t - \mathbf{C}_t \bar{\boldsymbol{\mu}}_{x_t} + \mathbf{C}_t \bar{\boldsymbol{\mu}}_{x_t} - \mathbf{C}_t \mathbf{x}_t = \mathbf{z}_t - \mathbf{C}_t \bar{\boldsymbol{\mu}}_{x_t} + \mathbf{C}_t (\bar{\boldsymbol{\mu}}_{x_t} - \mathbf{x}_t) = (\mathbf{z}_t - \mathbf{C}_t \bar{\boldsymbol{\mu}}_{x_t}) - \mathbf{C}_t (\mathbf{x}_t - \bar{\boldsymbol{\mu}}_{x_t})$$

- 이를 기존 식에 대입해보면

$$\bar{\Sigma}_{x_t}^{-1} (\mathbf{x}_t - \bar{\boldsymbol{\mu}}_{x_t}) - \mathbf{C}_t^\top \mathbf{Q}^{-1} ((\mathbf{z}_t - \mathbf{C}_t \bar{\boldsymbol{\mu}}_{x_t}) - \mathbf{C}_t (\mathbf{x}_t - \bar{\boldsymbol{\mu}}_{x_t})) = 0$$

$$\rightarrow \bar{\Sigma}_{x_t}^{-1} (\mathbf{x}_t - \bar{\boldsymbol{\mu}}_{x_t}) + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t (\mathbf{x}_t - \bar{\boldsymbol{\mu}}_{x_t}) = \mathbf{C}_t^\top \mathbf{Q}^{-1} (\mathbf{z}_t - \mathbf{C}_t \bar{\boldsymbol{\mu}}_{x_t})$$

$$\rightarrow (\bar{\Sigma}_{x_t}^{-1} + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t) (\mathbf{x}_t - \bar{\boldsymbol{\mu}}_{x_t}) = \mathbf{C}_t^\top \mathbf{Q}^{-1} (\mathbf{z}_t - \mathbf{C}_t \bar{\boldsymbol{\mu}}_{x_t})$$

$$\rightarrow (\mathbf{x}_t - \bar{\boldsymbol{\mu}}_{x_t}) = (\bar{\Sigma}_{x_t}^{-1} + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t)^{-1} \mathbf{C}_t^\top \mathbf{Q}^{-1} (\mathbf{z}_t - \mathbf{C}_t \bar{\boldsymbol{\mu}}_{x_t})$$

Kalman Filter - Kalman Gain derivation

- 즉, 우리가 원하는 최종 state는 아래와 같이 표현 가능

$$\mathbf{x}_t = \bar{\mu}_{x_t} + \underbrace{(\bar{\Sigma}_{x_t}^{-1} + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t)^{-1} \mathbf{C}_t^\top \mathbf{Q}^{-1}}_{\mathbf{K}_t \text{ (Kalman Gain!)}} (\mathbf{z}_t - \mathbf{C}_t \bar{\mu}_{x_t})$$

- 근데 Kalman Gain은 ..?

$$\mathbf{K}_t = \bar{\Sigma}_{x_t} \mathbf{C}_t^\top \left(\mathbf{C}_t \bar{\Sigma}_{x_t} \mathbf{C}_t^\top + \mathbf{Q} \right)^{-1}$$

- 근데 저희가 아는 Kalman gain이랑 모양이 조금 다른데요...
- 그리고 Correction state라면서 왜 mean만 가지고 계산해요...?
 - 일단은 하나하나 봐보아요..

Kalman Filter - Kalman Gain derivation

- 그러니까... 일단 Kalman Gain부터 보면, '아래 두 식이 결국 같은거다' 라는 이야기입니다.
 - Woodbury identity를 이용해서 증명 가능

$$\left(\bar{\Sigma}_{x_t}^{-1} + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t\right)^{-1} \mathbf{C}_t^\top \mathbf{Q}^{-1} \stackrel{?}{=} \bar{\Sigma}_{x_t} \mathbf{C}_t^\top \left(\mathbf{C}_t \bar{\Sigma}_{x_t} \mathbf{C}_t^\top + \mathbf{Q}\right)^{-1}$$

- Woodbury identity로 증명 가능하지만, Kalman Gain의 최종적인 형태를 모를때는 어떻게 저 Kalman filter 형태로 어떻게 뽑아내느냐...
 - 역행렬의 성질

$$\mathbf{A}^{-1} \mathbf{A} = \mathbf{I}, \quad \mathbf{A} \mathbf{A}^{-1} = \mathbf{I}$$

Kalman Filter - Kalman Gain derivation

- 식을 잠깐 정리하고,

$$\begin{aligned} & (\bar{\Sigma}_{x_t}^{-1} + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t)^{-1} \mathbf{C}_t^\top \mathbf{Q}^{-1} \\ \rightarrow & [\bar{\Sigma}_{x_t}^{-1} (\mathbf{I} + \bar{\Sigma}_{x_t} \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t)]^{-1} \mathbf{C}_t^\top \mathbf{Q}^{-1} \\ \rightarrow & (\mathbf{I} + \bar{\Sigma}_{x_t} \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t)^{-1} \bar{\Sigma}_{x_t} \mathbf{C}_t^\top \mathbf{Q}^{-1} \end{aligned}$$

- 다시, 이 식을 $\mathbf{X}$, $\mathbf{Y}$ 의 조합으로 치환하면,

$$\mathbf{X} = \bar{\Sigma}_{x_t} \mathbf{C}_t^\top, \quad \mathbf{Y} = \mathbf{Q}^{-1} \mathbf{C}_t, \quad (\mathbf{I} + \mathbf{X}\mathbf{Y})^{-1} \mathbf{X}\mathbf{Q}^{-1}$$

Kalman Filter - Kalman Gain derivation

- $\mathbf{Q}^{-1}$ 는 맨 마지막에 다시 곱해주면 되니 $\mathbf{XY}$ 만 가지고 해보면,
 - 그 전에, 분배법칙과 역행렬로 앞선 식으로 다시 돌아올것(Kalman Gain 형태를 가져오기 위해서 이런 식으로..)

$$(\mathbf{I} + \mathbf{XY})\mathbf{X} = \mathbf{X} + \mathbf{XYX} = \mathbf{X}(\mathbf{I} + \mathbf{YX})$$

- 괄호항의 Inverse를 곱하기

$$(\mathbf{I} + \mathbf{XY})^{-1}(\mathbf{I} + \mathbf{XY})\mathbf{X} = (\mathbf{I} + \mathbf{XY})^{-1}\mathbf{X}(\mathbf{I} + \mathbf{YX})$$

$$\mathbf{X} = (\mathbf{I} + \mathbf{XY})^{-1}\mathbf{X}(\mathbf{I} + \mathbf{YX})$$

$$\mathbf{X}(\mathbf{I} + \mathbf{YX})^{-1} = (\mathbf{I} + \mathbf{XY})^{-1}\mathbf{X}$$

$$\therefore (\mathbf{I} + \mathbf{XY})^{-1}\mathbf{X}\mathbf{Q}^{-1} = \mathbf{X}(\mathbf{I} + \mathbf{YX})^{-1}\mathbf{Q}^{-1}$$

Kalman Filter - Kalman Gain derivation

- 다시 원상복구를 해보면

$$\bar{\Sigma}_{x_t} \mathbf{C}_t^\top (\mathbf{I} + \mathbf{Q}^{-1} \mathbf{C}_t \bar{\Sigma}_{x_t} \mathbf{C}_t^\top)^{-1} \mathbf{Q}^{-1}$$

$$\therefore \mathbf{K}_t = \bar{\Sigma}_{x_t} \mathbf{C}_t^\top (\mathbf{Q} + \mathbf{C}_t \bar{\Sigma}_{x_t} \mathbf{C}_t^\top)^{-1}$$

- 아까 이게 같았던 그 식

$$\left(\bar{\Sigma}_{x_t}^{-1} + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t \right)^{-1} \mathbf{C}_t^\top \mathbf{Q}^{-1} \stackrel{?}{=} \bar{\Sigma}_{x_t} \mathbf{C}_t^\top \left(\mathbf{C}_t \bar{\Sigma}_{x_t} \mathbf{C}_t^\top + \mathbf{Q} \right)^{-1}$$

- 따라서, Kalman Gain 증명 끝!

Kalman Filter - final state

- 그래서 Kalman Gain이 뭘 의미하는가...
 - 극단적으로, $\mathbf{C}_t$ 가 1인 경우
 - Distortion, Projection 없이 그대로 측정한 경우라고 '가정'
- 그렇다면, $\mathbf{K}_t$ 는 $\bar{\Sigma}_{x_t}(\bar{\Sigma}_{x_t} + \mathbf{Q})^{-1}$ 이 됨
 - 결국 비율문제!
 - 예측한 내 state의 불확실성과 sensor의 불확실성을 모두 고려할 때, 내 불확실성이 차지하는 비중은?
 - 내 불확실성이 크면, K가 커져서 관측값을 더 신뢰하고, 불확실성이 작다면, K가 작아져서 예측값을 더 신뢰하도록!
- 최종적으로, 앞서 구한 Kalman gain을 이용한 최종 state는 아래와 같이 표현 가능

$$\mathbf{x}_t = \bar{\mu}_{x_t} + \mathbf{K}_t(\mathbf{z}_t - \mathbf{C}_t\bar{\mu}_{x_t})$$

Kalman Filter - final state

- 해서, 두 번째 이상한 부분 - 왜 mean만 가지고 $\mathbf{x}_t$ 라고 했어?
 - 사실, 이 녀석은 최종적으로 estimation된 mean입니다.

$$\boldsymbol{\mu}_t = \bar{\boldsymbol{\mu}}_{x_t} + \mathbf{K}_t(\mathbf{z}_t - \mathbf{C}_t\bar{\boldsymbol{\mu}}_{x_t})$$

- 즉, final state의 mean일거라는 것이지요.

$$\mathbf{x}_t \sim \mathcal{N}(\boldsymbol{\mu}_t, \boldsymbol{\Sigma}_t)$$

- 그러면 $\boldsymbol{\Sigma}_t$ 는 어떻게 구하나요?
 - 아까 전개해두었던 수식의 2차항!

$$\left(\mathbf{x}_t^\top (\bar{\boldsymbol{\Sigma}}_{x_t}^{-1} + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t) \mathbf{x}_t - 2\bar{\boldsymbol{\mu}}_{x_t}^\top \bar{\boldsymbol{\Sigma}}_{x_t}^{-1} \mathbf{x}_t - 2\mathbf{z}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t \mathbf{x}_t + const \right)$$

Kalman Filter - final state

- 왜 2차항만 보나?
 - 1차항 부분들은, 결국 mean에 대한 shift만 할 뿐, covariance에는 영향을 주지 않음
 - 즉, 2차항이 곧 correction 된 covariance!

$$\Sigma_t = (\bar{\Sigma}_{x_t}^{-1} + \mathbf{C}_t^\top \mathbf{Q}^{-1} \mathbf{C}_t)^{-1}$$

- Kalman Gain을 이용해서 표현해보면,
 - Woodbury identity를 이용해서 유도하면

$$(\mathbf{A} + \mathbf{UBV})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1}\mathbf{U}(\mathbf{B} + \mathbf{VA}^{-1}\mathbf{U})^{-1}\mathbf{VA}^{-1}$$

$$\rightarrow \Sigma_t = \bar{\Sigma}_{x_t} - \bar{\Sigma}_{x_t} \mathbf{C}_t^\top (\mathbf{Q} + \mathbf{C}_t \bar{\Sigma}_{x_t} \mathbf{C}_t^\top)^{-1} \mathbf{C}_t \bar{\Sigma}_{x_t}$$

$$\therefore \Sigma_t = \bar{\Sigma}_{x_t} - \mathbf{K}_t \mathbf{C}_t \bar{\Sigma}_{x_t} = (\mathbf{I} - \mathbf{K}_t \mathbf{C}_t) \bar{\Sigma}_{x_t}$$

Kalman Filter - final state

- 따라서, Kalman Filter의 최종적인 state는 아래와 같이 표현 가능, 끝!

$$\mathbf{x}_t \sim \mathcal{N}(\boldsymbol{\mu}_t, \boldsymbol{\Sigma}_t)$$

- 다음은, 선형을 비선형으로 바꾼, Extended Kalman Filter(EKF)로
 - 쉬울거예요, Taylor expansion만 하면 되니까요?

Extended Kalman Filter

- 선형 시스템에서 비선형 시스템으로의 확장
- 그렇게 어렵지 않다!
- EKF는 시스템 모델과 관측 모델이 비선형 함수로 표현된다고 가정
- 선형화를 위해서, Taylor expansion을 이용하여 시스템 모델과 관측 모델을 선형 근사
 - Taylor series, expansion, appoximation...

$$f(x) \approx f(x_0) + f(x_0)'(x - x_0) + \frac{1}{2}f(x_0)''(x - x_0)^2 + \dots$$


$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0)$$

Extended Kalman Filter - Taylor expansion

- 그림으로 보면 이렇게 볼 수 있지요
- 1st order approximation : 임의의 함수를 선형으로 근사해서, 궁금한 지점에서의 함수값의 근사치를 구하는 방법

$$f(x) \approx f(a) + f'(a)(x - a)$$

- Gradient descent, Newton's method 등에서 활용




Extended Kalman Filter - Taylor expansion

- 2nd order approximation : 임의의 함수를 2차식으로 근사해서, 궁금한 지점에서의 함수값의 근사치를 구하는 방법

$$f(x) \approx f(a) + f'(a)(x - a) + \frac{1}{2}f''(a)(x - a)^2$$

- 기울기 뿐만 아니라, 기존 함수의 곡률도 고려해서 근사하겠다
 - 곡률까지 고려한만큼, 훨씬 더 정확한 근사치 제공



Extended Kalman Filter - 1st order approximation

- Taylor expansion을 이용해서, KF를 EKF로!
- EKF에서는 1st-order approximation을 이용해서 시스템 모델과 관측 모델을 선형화
- 이 때, 선형화 과정에서 벡터를 벡터로 미분한 Jacobian 사용
- Gradient 가 아니라 대부분 Jacobian을 씀 왜?
 - state는 단순한 하나의 변수가 아님; 다변수임(pose, velocity, bias 등등)

Extended Kalman Filter - 1st order approximation

- Gradient: 스칼라 함수의 벡터 입력에 대한 편미분

$$\nabla f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}$$

- Jacobian: 벡터 함수의 벡터 입력에 대한 편미분

$$\mathbf{J}(\mathbf{x}) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \frac{\partial f_m}{\partial x_2} & \cdots & \frac{\partial f_m}{\partial x_n} \end{pmatrix}$$

Extended Kalman Filter - 1st order approximation

- Hessian: 스칼라 함수의 벡터 입력에 대한 이차 편미분

$$\mathbf{H}(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$$

- 최적화 기법 중 Gauss-Newton method에서는 Jacobian을 이용해서 Hessian을 근사

$$\mathbf{H} \approx \mathbf{J}^\top \mathbf{J}$$

Extended Kalman Filter

- 우리가 알고있는 KF의 motion model을, Non-linear system으로 표현해보면

$$\mathbf{x}_t = f(\mathbf{x}_{t-1}, \mathbf{u}_t) + \mathbf{w}_t = \boldsymbol{\mu}_t + \mathbf{w}_t, \quad \mathbf{w}_t \sim \mathcal{N}(0, \mathbf{R}_t)$$

- EKF에서는, 비선형 시스템 모델이 이전 state의 평균을 기준으로 선형화된다고 가정

$$f(\mathbf{x}_{t-1}, \mathbf{u}_t) \approx f(\boldsymbol{\mu}_{t-1}, \mathbf{u}_t) + \mathbf{J}_t(\mathbf{x}_{t-1} - \boldsymbol{\mu}_{t-1})$$

$$\mathbf{x}_t = f(\mathbf{x}_{t-1}, \mathbf{u}_t) + \mathbf{w}_t = f(\boldsymbol{\mu}_{t-1}, \mathbf{u}_t) + \mathbf{J}_t(\mathbf{x}_{t-1} - \boldsymbol{\mu}_{t-1}) + \mathbf{w}_t$$

$$\mathbf{J}_t = \left. \frac{\partial f(\mathbf{x}_{t-1}, \mathbf{u}_t)}{\partial \mathbf{x}_{t-1}} \right|_{\mathbf{x}_{t-1} = \boldsymbol{\mu}_{t-1}}$$

Extended Kalman Filter

- $f(\boldsymbol{\mu}_{t-1}, \mathbf{u}_t)$ 만 다시 보면, $f(\mathbf{x}_{t-1}, \mathbf{u}_t) \approx f(\boldsymbol{\mu}_{t-1}, \mathbf{u}_t) + \mathbf{J}_t(\mathbf{x}_{t-1} - \boldsymbol{\mu}_{t-1})$ quad

$$f(x) \approx f(x_0) + f'(x_0)(x - x_0)$$

Taylor series랑 똑같쥬?

- 그럼, motion model에서의 mean, covariance는?
 - 이전 state는 정확히 알고있다!(KF에서의 가정)

$$\mathbf{x}_{t-1} = \mathcal{N}(\boldsymbol{\mu}_{t-1}, \boldsymbol{\Sigma}_{t-1}) = \mathcal{N}(0, 0)$$

Extended Kalman Filter

Iterated Error State Kalman Filter (IESKF)

<!-- ----

Iterated Error State Kalman Filter (IESKF)

Iterated Error State Kalman Filter (IESKF)

- Gauss newton과 뭐가 흡사한지 보자
- 그리고 난 뒤에, IKF의 프로세스를 정리해보자
- 여기서부터 FAST LIO2를 입혀서, forward passing과 backward에서 lidar undistortion을 묶어서 설명하고, R3LIVE를 정리하자. 그렇게 끝내자. -->