

F4Splat: Feed-Forward Predictive Densification for Feed-Forward 3D Gaussian Splatting

2026 (arXiv)

Injae Kim¹, Chaehyeon Kim¹, Minseong Bae¹, Minseok Joo², and Hyeonwoo J. Kim¹

¹ KAIST

² Korea University

Computer Vision and Robotics Lab

Minsu Kim

2026.06.04

Contents

1. Introduction
2. Related Work
3. Method
4. Experiments
5. Conclusion

Introduction

- 3D Reconstruction, 또는 NVS(Novel View Synthesis) 분야에서, NeRF를 이어 3DGS가 등장했는데, scene densification을 주로 ADC(Adaptive Density Control)로 해결
 - Densification 관점에서는 좋지만, 최적화를 통해 지속적으로 복제, 분할, 제거를 수행해야 함
 - 연산도 연산이지만, 불필요하게 Gaussian이 많아질 수 있음
- 따라서, 정확한 Prior를 예측해서 ADC의 역할 자체를 줄여보자는 아이디어가 feed-forward 3DGS 계열의 main 아이디어
 - 대부분 pixel-to-Gaussian으로 Gaussian을 생성하는데, 효율적이지 못함
 - 넓은 부분은 하나로만 해도 되는데, pixel마다 다 만들기 때문
- 따라서, Anysplat 같이 voxel의 크기를 조절하여 효율성을 높이도록 함
 - 하지만, Anysplat은 voxel의 크기를 조절할 뿐, 여전히 voxel 내에선 uniform하게 Gaussian을 생성

Introduction

- 앞서 언급한 문제들을 다루고자 f4splat을 제안
- Uncalibrated image로부터 3DGS를 예측하는 feed-forward 3DGS 방법
- 제한된 Budget 내에서, densification score를 기반으로 non-uniform하게 Gaussian을 생성
 - Densification score를 통해 non-uniform하게 Gaussian을 생성하여 효율성을 높임
 - 진짜 필요한 부분에만 Gaussian 만들도록!

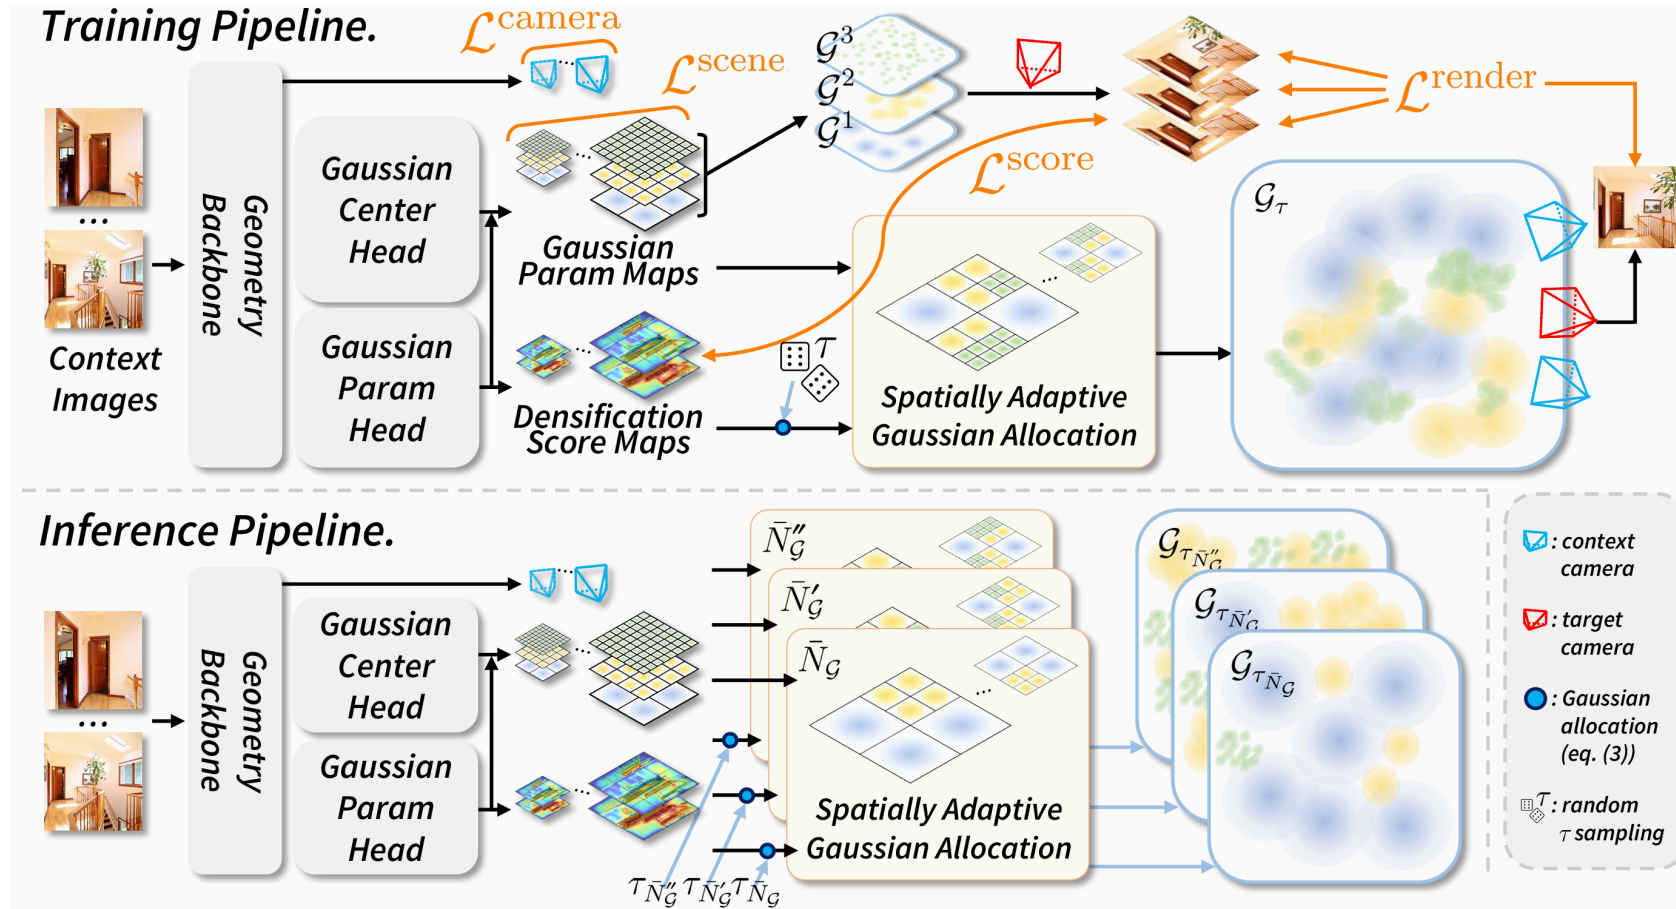
Related Work

- NeRF 계열은 neural scene representation의 기본 흐름을 만들었지만, per-ray volumetric rendering 때문에 계산 비용이 큼; 그래서 더 빠른 대안으로 3DGS가 등장
- 3DGS는 3D Gaussian primitive + differentiable rasterization으로 장면을 표현해서, NeRF보다 빠른 최적화와 실시간 렌더링이 가능
 - ADC로 부족한 영역에는 Gaussian을 추가하고, 기여도 낮은 Gaussian은 제거
- 기존 3DGS의 한계는 dense-view와 per-scene iterative optimization이다. 안정적인 재구성을 위해 많은 입력 view가 필요하고 매 장면마다 최적화를 다시 해야 해서 실용적으로 부담이 큼
- 위의 문제를 해결하기 위해 Feed-forward 3DGS는 이 문제를 줄이기 위해 등장
 - 대규모 데이터셋에서 prior를 학습해두고, 새로운 장면에서는 **iterative optimization 없이** 한 번의 forward pass로 Gaussian을 예측
 - 초기에는 calibrated input을 가정했고, 이후 pose-free, self-supervised pose-free, uncalibrated setting으로 발전

Related Work

- 하지만 기존 feed-forward 3DGS는 Gaussian allocation이 비효율적임
 - 대부분 pixel 또는 voxel마다 고정된 수의 Gaussian을 배치하기 때문에 단순한 영역에는 중복이 생기고, 복잡한 영역에는 부족해짐
- 이 문제를 다룬 대표적인 논문이 **AnySplat**
 - Voxel 크기로 Gaussian 수를 조절하지만 여전히 **uniform allocation**이고 budget 변경 시 재학습 필요
- 따라서, F4Splat은 budget-aware densification score로 non-uniform, spatially adaptive allocation을 하겠다는 것!

Method



Method - Problem Formulation

- 입력 context image N_{ctx} 가 주어졌을 때, 대부분의 기존 **feed-forward 3DGS** 방법들은 pixel마다 Gaussian 생성

$$\{\mathbf{I}_i^{ctx}\}_{i=1}^{N_{ctx}}, \quad \mathbf{I}_i^{ctx} \in \mathbb{R}^{3 \times H \times W}, \quad N_{ctx}HW$$

- **F4Splat**에서는, 각 pixel마다 Gaussian을 생성하는 대신, **densification score**를 예측해서 non-uniform하게 Gaussian을 생성
 - User-specified target budget $\bar{N}_G$ 도 입력으로 받아 최대 Gaussian 수를 조절할 수 있도록 함
 - 최종 출력은 3D Gaussian primitive set $\mathcal{G} = \{\mathbf{g}_g\}_{g=1}^{N_G}$ 와 camera parameter $\{\hat{\mathbf{P}}_{i=1}^{N_{ctx}}\}$

$$(\mathcal{G} = \{\mathbf{g}_g\}_{g=1}^{N_G}, \{\hat{\mathbf{P}}_{i=1}^{N_{ctx}}\}) = \mathbf{F}_\theta(\{\mathbf{I}_{i=1}^{ctx}, \bar{N}_G)$$

Method - Problem Formulation

- 각 Gaussian $\mathbf{g}_g \in \mathbb{R}^{d_g}$ 는 center, opacity, quaternion, scale, SH coefficient로 구성

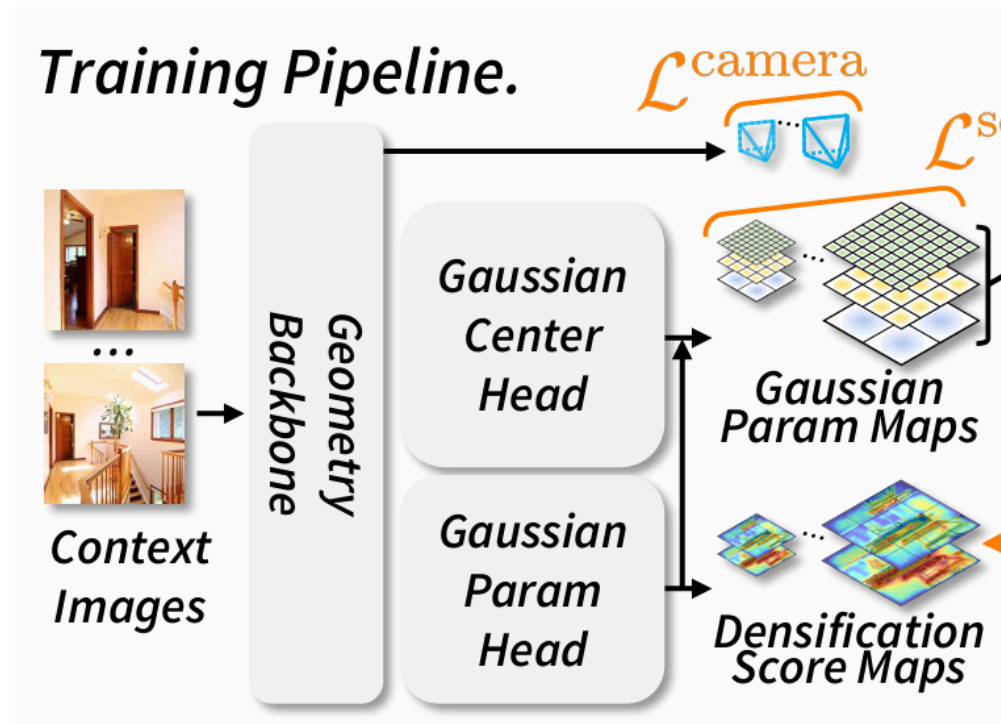
$$\boldsymbol{\mu}_g \in \mathbb{R}^3, \sigma_g \in \mathbb{R}, \mathbf{q}_g \in \mathbb{R}^4, \mathbf{s}_g \in \mathbb{R}^3, \mathbf{h}_g \in \mathbb{R}^\nu$$

- 각 Camera parameter는 intrinsic, extrinsic으로 구성
 - $\hat{\mathbf{K}}_i^{ctx}$ 내부의 focal length $\hat{f}_i^{ctx}$ 도 예측
 - $(\hat{\cdot})$, hat이 붙은 모든 변수들은 network prediction

$$\hat{\mathbf{P}}_i^{ctx} = (\hat{\mathbf{K}}_i^{ctx}, \hat{\mathbf{T}}_i^{ctx})$$

Method - Spatially Adaptive Gaussian Allocation

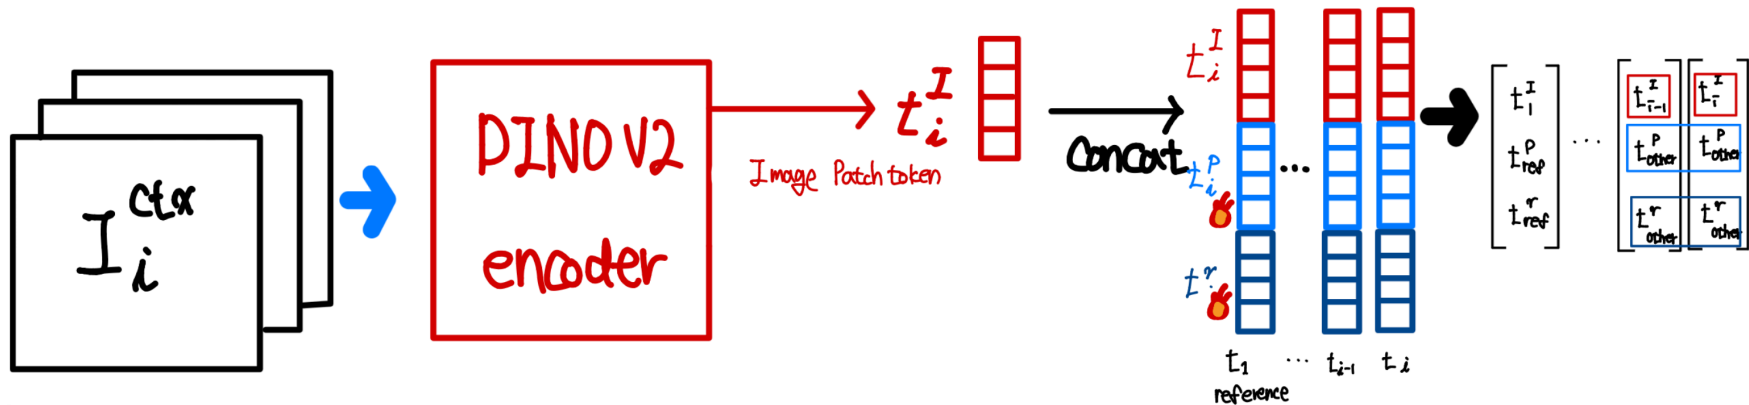
- Multi-view image set을 받아 Geometry backbone이 camera parameter 예측
- Gaussian Center head와 parameter head는 각각 Gaussian의 center, 그리고 나머지 parameter를 예측
 - 여기서 densification score도 예측해서, non-uniform하게 Gaussian을 생성하도록 함



Method - Spatially Adaptive Gaussian Allocation

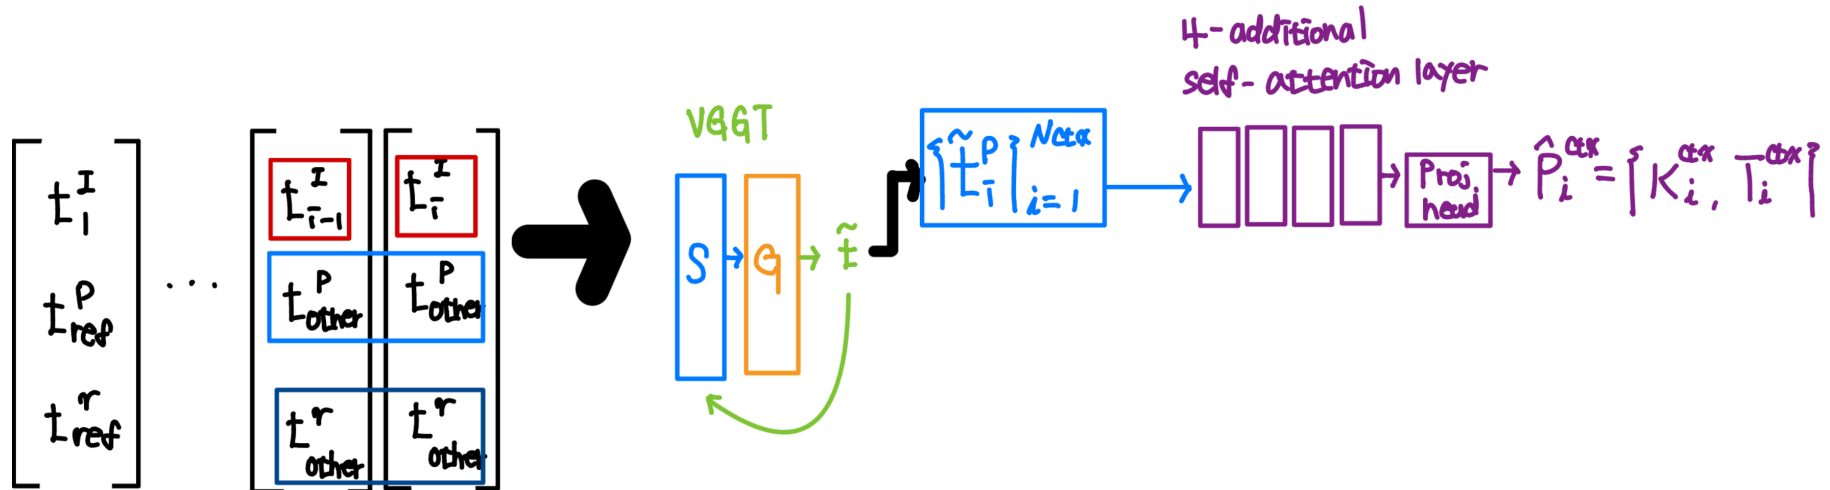
Geometry backbone

- Image를 input으로 받아, DINO V2 encoder로 token 추출
- 이후 학습 가능한 Camera parameter, register token을 concat하여 VGGT 입력 준비
 - 1번째 image를 reference로 하여 token을 따로 두고, 나머지 token은 우선 other token으로 둬



Method - Spatially Adaptive Gaussian Allocation

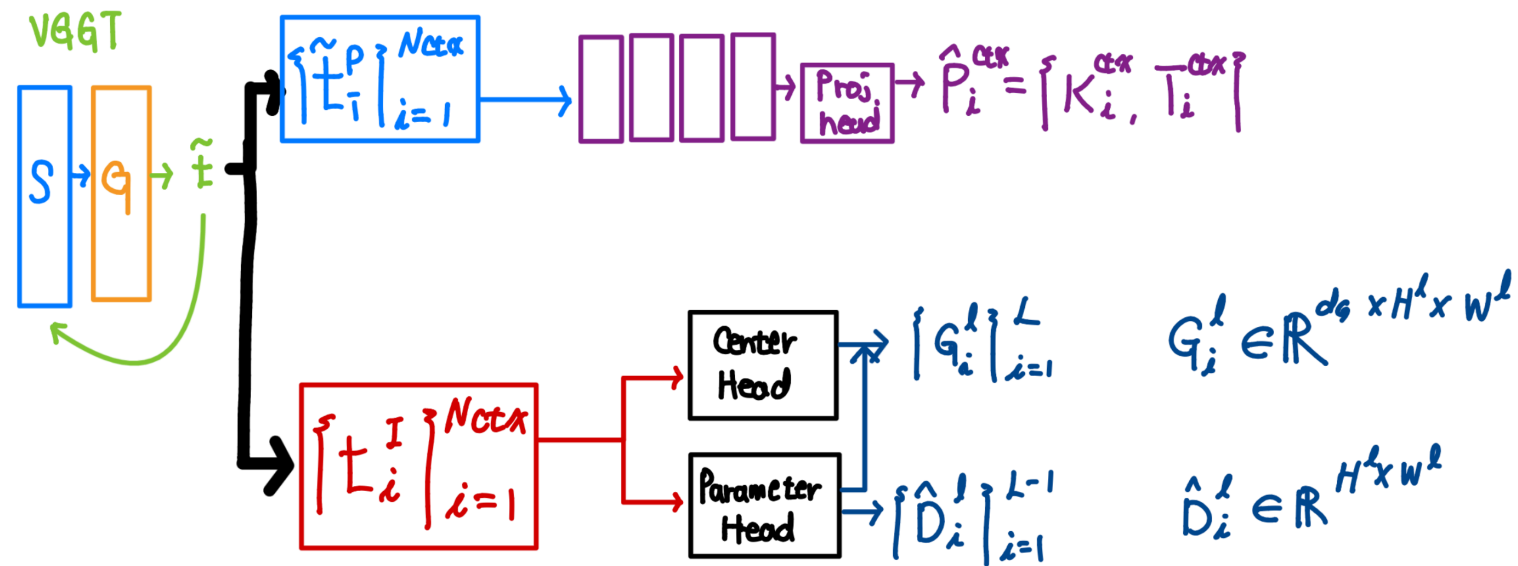
- 정리한 Token들을 self, global attention layer로 구성된 VGGT-like? 구조에 넣어서 각 token 업데이트
 - 반복적으로 수행할텐데, VGGT를 따랐다면 24번 반복해서 최종 token $\tilde{\mathbf{t}}_i^{ctx}$ 출력
- 여기서 Camera parameter token만 따로 4개 추가 self-attention layer에 넣어서 최종 camera parameter $\hat{\mathbf{P}}_i^{ctx}$ 예측



Method - Spatially Adaptive Gaussian Allocation

Multi-Scale Prediction

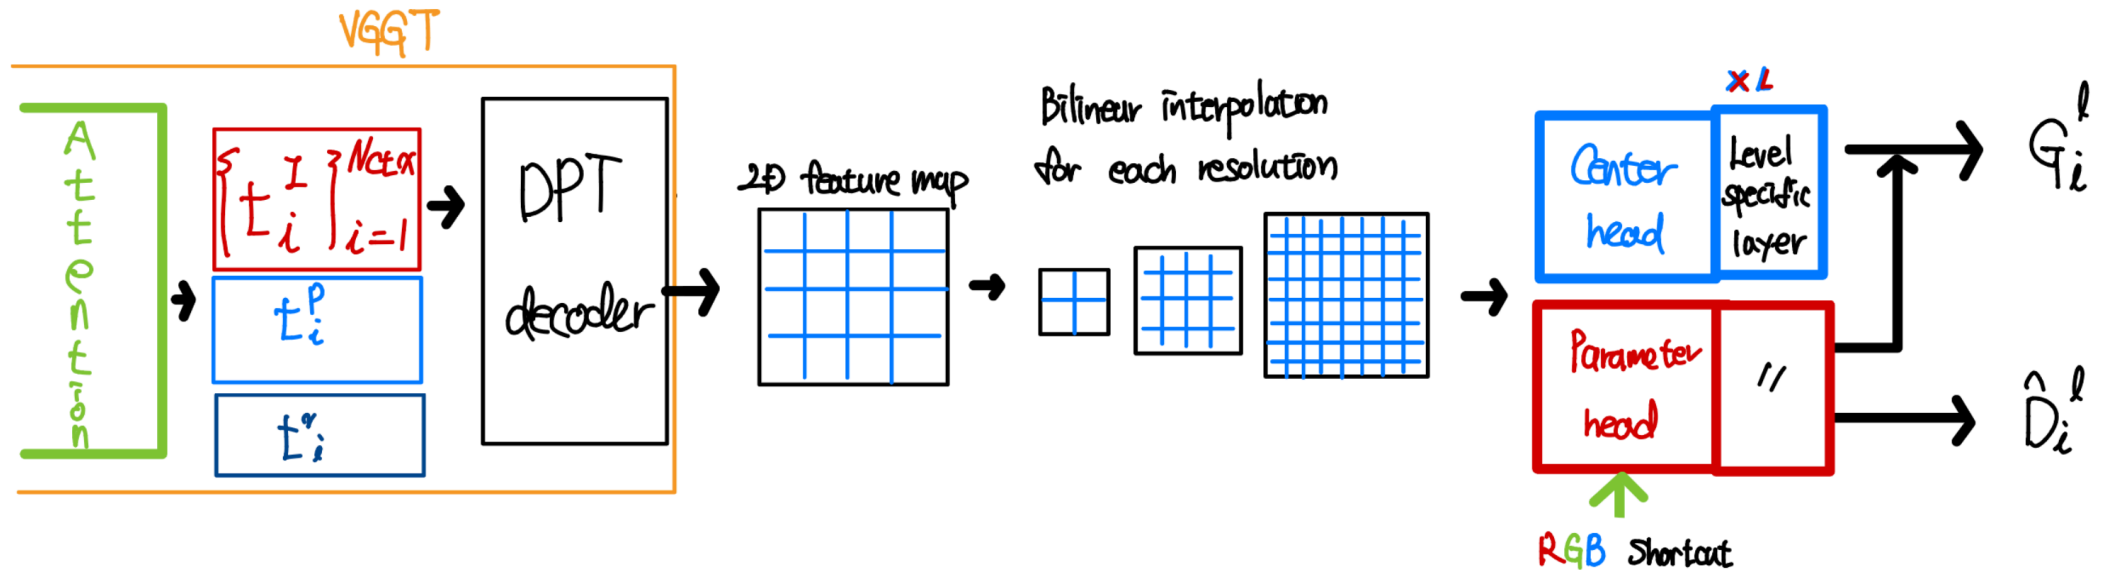
- VGGT의 output token 중, Image token $\mathbf{t}_i^I$ 을 각각 Gaussian center, Gaussian parameter head에 넣음



Method - Spatially Adaptive Gaussian Allocation

- 다만, 여기서 output으로 나오는 $\mathbf{G}_i$ 와 $\hat{\mathbf{D}}_i$ 가 하나는 아님
 - Multi-scale이기 때문에, 각각 $\{\mathbf{G}_i\}_{l=1}^L$ 와 $\hat{\mathbf{D}}_i^{L-1}$ 로 나옴($L = 3$)
 - 각 level 마다의 resolution

$$l = 1 : \left(\frac{H}{4}, \frac{W}{4}\right), \quad l = 2 : \left(\frac{H}{2}, \frac{W}{2}\right), \quad l = 3 : (H, W)$$



Method - Spatially Adaptive Gaussian Allocation

- 전체 Gaussian의 개수 $N_{\mathcal{G}}$

$$N_{ctx}H^1W^1 \leq N_{\mathcal{G}} \leq N_{ctx}H^3W^3$$

$$\rightarrow \frac{N_{ctx}HW}{16} \leq N_{\mathcal{G}} \leq N_{ctx}H^3W^3$$

Method - Spatially Adaptive Gaussian Allocation

- 각 레벨마다 Gaussian 후보도 알았고, densification score도 얻었으니, 어떤 레벨에서 몇 개의 Gaussian을 생성할지 결정하면 됨
- 기하학적으로, photometric적으로도 더 복잡한 부분에 Gaussian이 많이 할당되어야 함
 - 아래수식을 통해 각 level마다 Gaussian을 할당

$$\mathcal{M}_{\tau,i}^l = \begin{cases} \mathbf{1}_{\{\hat{\mathbf{D}}_i^l < \tau\}} & \text{if } l = 1, \\ \mathbf{1}_{\{\hat{\mathbf{D}}_i^l < \tau\}} \odot \left(\mathbf{1} - \sum_{k=1}^{l-1} \text{Up}(\mathcal{M}_{\tau,i}^{l-k}; 2^k) \right) & \text{if } 1 < l < L, \\ \mathbf{1} - \sum_{k=1}^{l-1} \text{Up}(\mathcal{M}_{\tau,i}^{l-k}; 2^k) & \text{if } l = L, \end{cases}$$

- 최종 Gaussian의 개수

$$N_{\mathcal{G}_\tau} = \sum_{l,t} \|\mathcal{M}_{\tau,i}^l\|_1$$

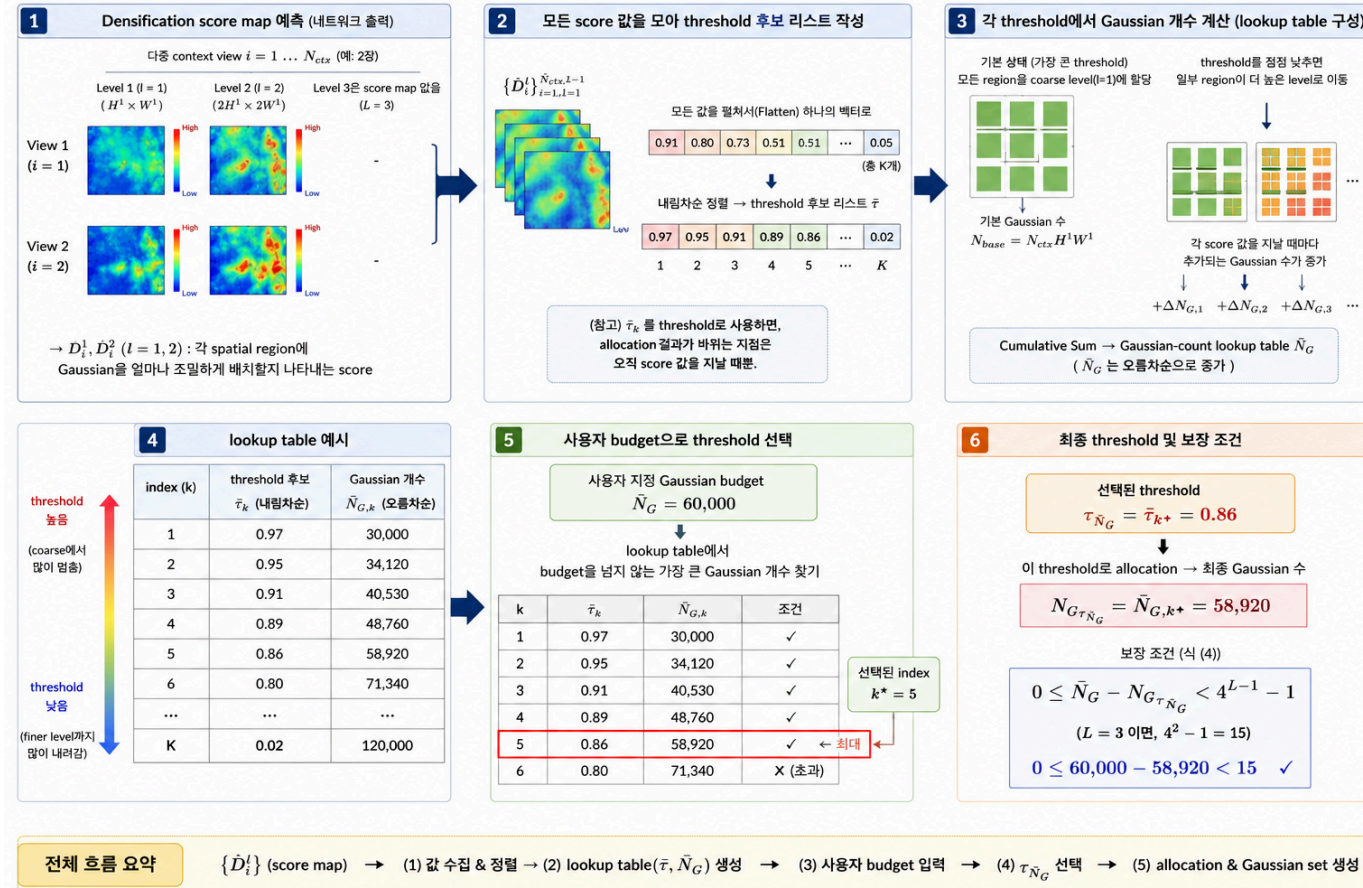
Method - Spatially Adaptive Gaussian Allocation

- Adaptive Gaussian Allocation을 위해 설정한 budget에 따라 다른 threshold τ 를 선택
 - τ 가 높을수록 fine 단계에서의 Gaussian이 많이 생성되기 때문!
- 아래 식으로, 사용자가 정한 budget이상 Gaussian이 생성되지 않도록!

$$0 \leq \bar{N}_{\mathcal{G}} - N_{\mathcal{G}_{\tau}} \leq 4^{L-1} - 1$$

- 풀어보면, 아무리 부족해도 15개 이상 차이나지 않도록 τ 를 조절

Method - Spatially Adaptive Gaussian Allocation



Method - Training strategy

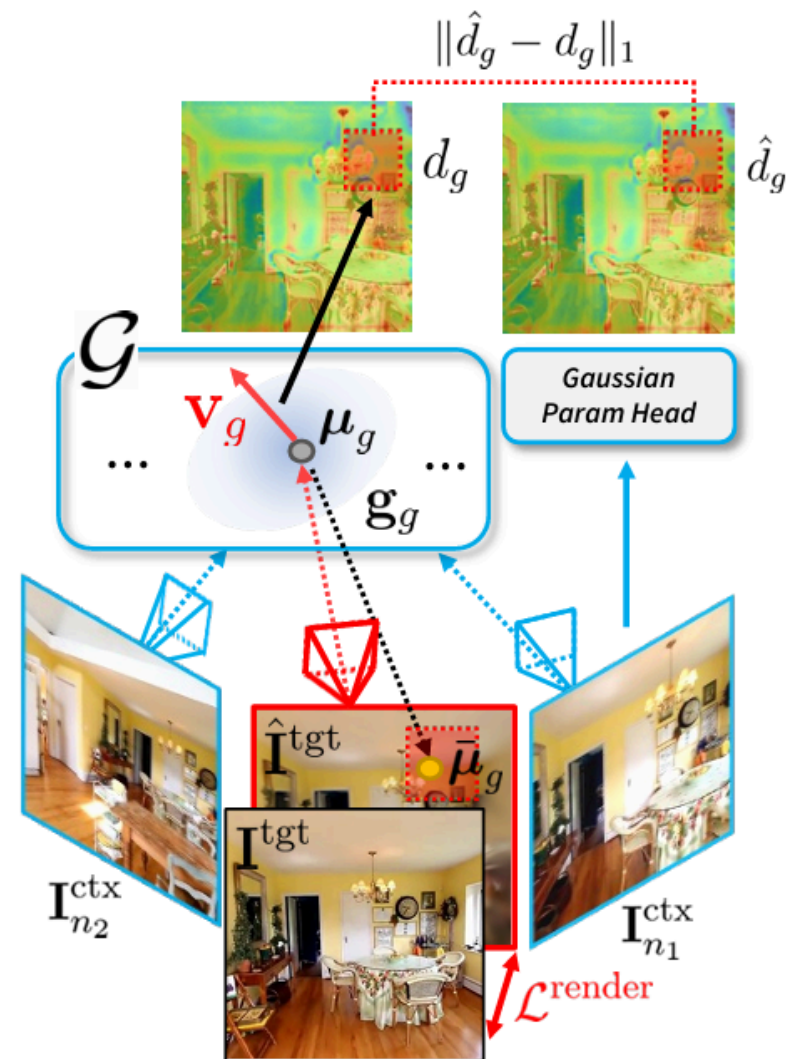
Feed-Forward Predictive Densification

- 본 논문에서 중요하게 생각하는 성질 두가지
 - **품질향상**을 고려해야함; 복잡한 곳에 더 많은 Gaussian을 할당할 수 있어야 함
 - Iterative optimization을 요구하지 않고, **inference time에 바로바로 사용** 할 수 있어야 함;
 - Densification score는 input image만 가지고 잘 계산되어야 한다..!
- 역설적이게도, ADC로부터 영감을 얻어 3DGS primitive들을 반복적으로 최적화함
- Inference 시에 optimization을 하면 loss를 미분해서 업데이트 하면 되지만, feed-forward에서는 optimization이라는 게 없다.
 - 그래서 **Training time에 rendering loss**를 구해서 densification score를 조절하는 방식으로

Method - Training strategy

- AbsGS 논문에서 했던 방식을 잠시 살펴 보면...
 - 예측된 Gaussian을 렌더링하여 GT image와 rendered image간의 MSE와 LPIPS loss를 구함 그것이 $\mathcal{L}_{\text{render}}$
- $\mathcal{L}_{\text{render}}$ 를 이용하여 **homodirectional view-space gradient vector** 계산

$$\mathbf{v}_g = \left(\sum_{j=1}^m \left| \frac{\partial \mathcal{L}_j^{\text{render}}}{\partial \bar{\mu}_{g,x}} \right|, \sum_{j=1}^m \left| \frac{\partial \mathcal{L}_j^{\text{render}}}{\partial \bar{\mu}_{g,y}} \right| \right)$$



Method - Training strategy

- 이게 도대체 무슨 이야기이고 하니...
- 앞서 설명했던 AbsGS 방식대로 하게되면, $\mathbf{v}_g$ 의 크기를 구함
 - 결국, gradient의 크기가 크다는 것은 gaussian이 불안정한 것이고, densification이 더 되어야 한다는 뜻
 - 더 문제는, feed-forward 방식에서 GT image라는건 존재하지 않음..!
- 그래서, training time에 **densification score**를 예측할 때 사용한다!
 - Network가 densification score를 통해 간접적으로 gradient를 사용한 학습하도록 하는 것!

$$d_g = \log(1 + 10^4 \cdot \|\mathbf{v}_g\|_2)$$

- 이 d_g 를 정답 score라고 생각!

Method - Training strategy

- 따라서, MLP가 densification score도 예측하는데(gaussian param head에서), 예측 값과 $\mathbf{v}_g$ 라고 생각한 값을 사용하여 학습

$$\mathcal{L}_{\mathcal{G}}^{\text{score}} = \mathbb{E}_{\mathbf{g}_g \in \mathcal{G}} \left[\|\hat{d}_g - d_g\|_1 \right]$$

- 결국, training 시에 densification score가 inference 시에 Gaussian allocation에 영향을 주는데, feed-forward의 optimization이 없는 상황에서도 Gaussian이 필요한 곳에 더 많이 할당되도록 학습

Method - Training Novel views

- 3DGS Training에서 항상 issue가 되어왔던 것은, GT pose에서만 학습을 하기 때문에,,
 - GT pose에 대해서만 랜더링 하고, 그 loss를 이용해 학습하기 때문에 overfitting 가능성 증가
 - Novel view에서 보면 랜더링 품질저하
- 따라서, 진짜 **novel view pose에서의 rendering loss**를 구해서 학습하도록 함
 - 먼저, GT space에서 predicted space $\mathbf{A} \in Sim(3)$ 를 추정함
 - 이 때, target view(novel view)의 가장 가까운 2개의 GT image의 pose와, 해당하는 frame에서 prediction한 image pose끼리의 변환을 추정
 - 변환된 결과 $\mathbf{A}$ 를 GT에 곱해서 predicted pose $\hat{\mathbf{T}}^{tgt}$ 추정

$$\hat{\mathbf{T}}^{tgt} = \mathbf{A}\mathbf{T}^{tgt}$$

Method - Training Novel views

- Camera parameter 중 pose는 완료했고 마지막으로 intrinsic parameter(focal length)
 - Focal length는 가장 가까운 view의 GT와 predicted focal length의 비율로 맞추어 계산

$$\frac{\hat{f}_{n1}^{ctx}}{f_{n1}^{ctx}}$$

- 최종 target focal length

$$\hat{f}^{tgt} = \frac{\hat{f}_{n1}^{ctx}}{f_{n1}^{ctx}} \cdot f^{tgt}$$

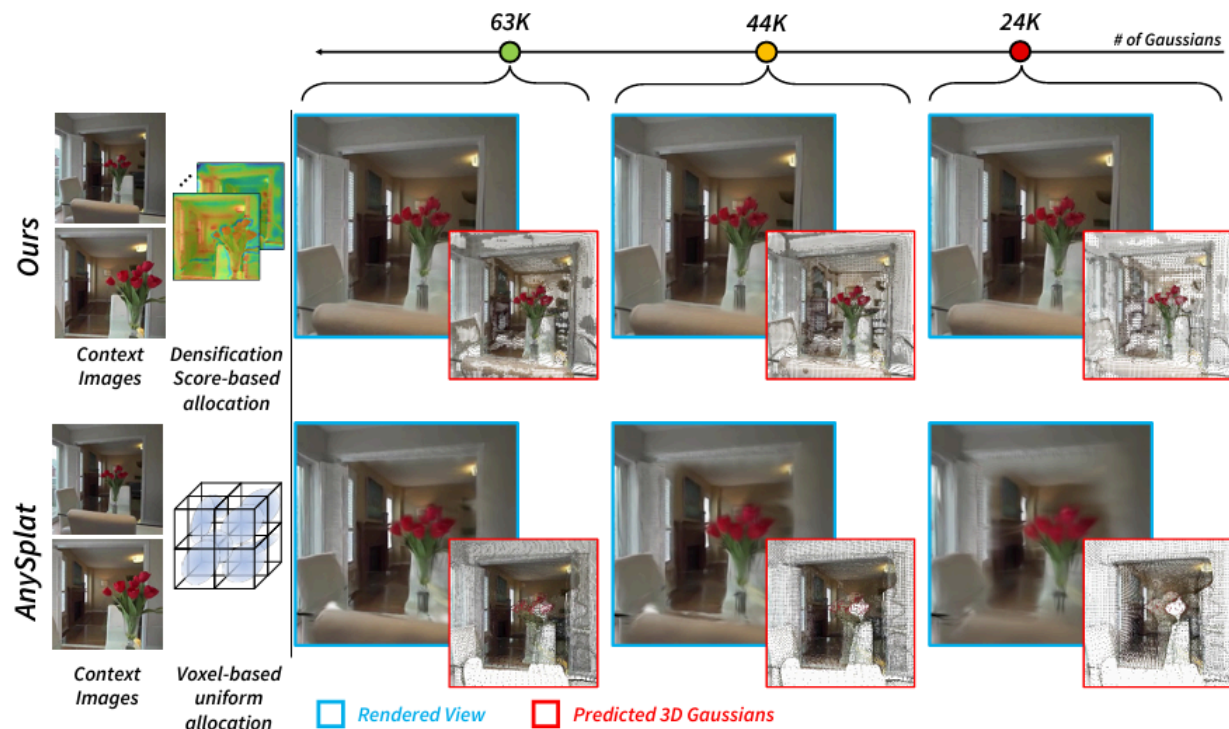
- 따라서, 앞서 예측한 intrinsic, extrinsic을 가지고 rendering 해서 Novel view를 training에 사용!

Method - Overall training pipeline

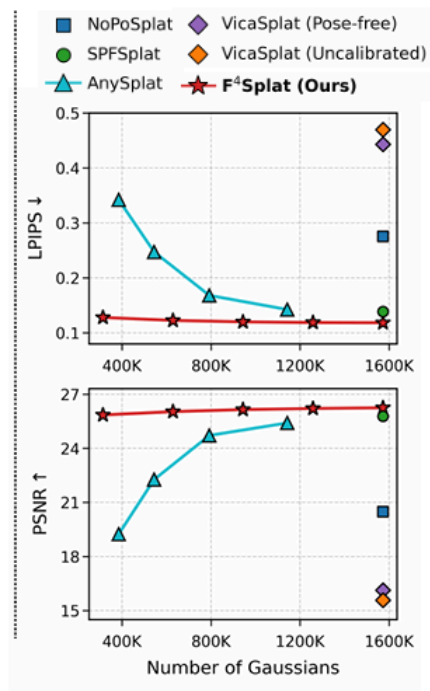
- Inference 때는 최대 budget을 설정하면 되지만, training 시에는 다양한 budget으로 학습해야 overfitting을 피할 수 있음
 - 따라서, random하게 τ 를 샘플링하여 학습
- 해당하는 threshold를 통과한 gaussian들을 가지고 랜더링해서 학습
 - $\mathcal{L}_{camera}$ 는 VGGT와 같이 학습, camera가 예측한 camera parameter를 Huber cost function을 씌워 최적화
 - $\mathcal{L}^{scene}$ 는 scene의 크기가 되도록 1이 되게끔 $\left| \frac{1}{|\mathcal{G}|} \sum_{\mathbf{g}_g \in \mathcal{G}} \|\boldsymbol{\mu}_g\|_2 - 1 \right|$ 로 normalization

$$\mathcal{L}_{total} = \mathcal{L}_{render} + \mathcal{L}_{score} + \mathcal{L}_{camera} + \mathcal{L}_{scene}$$

Experiments

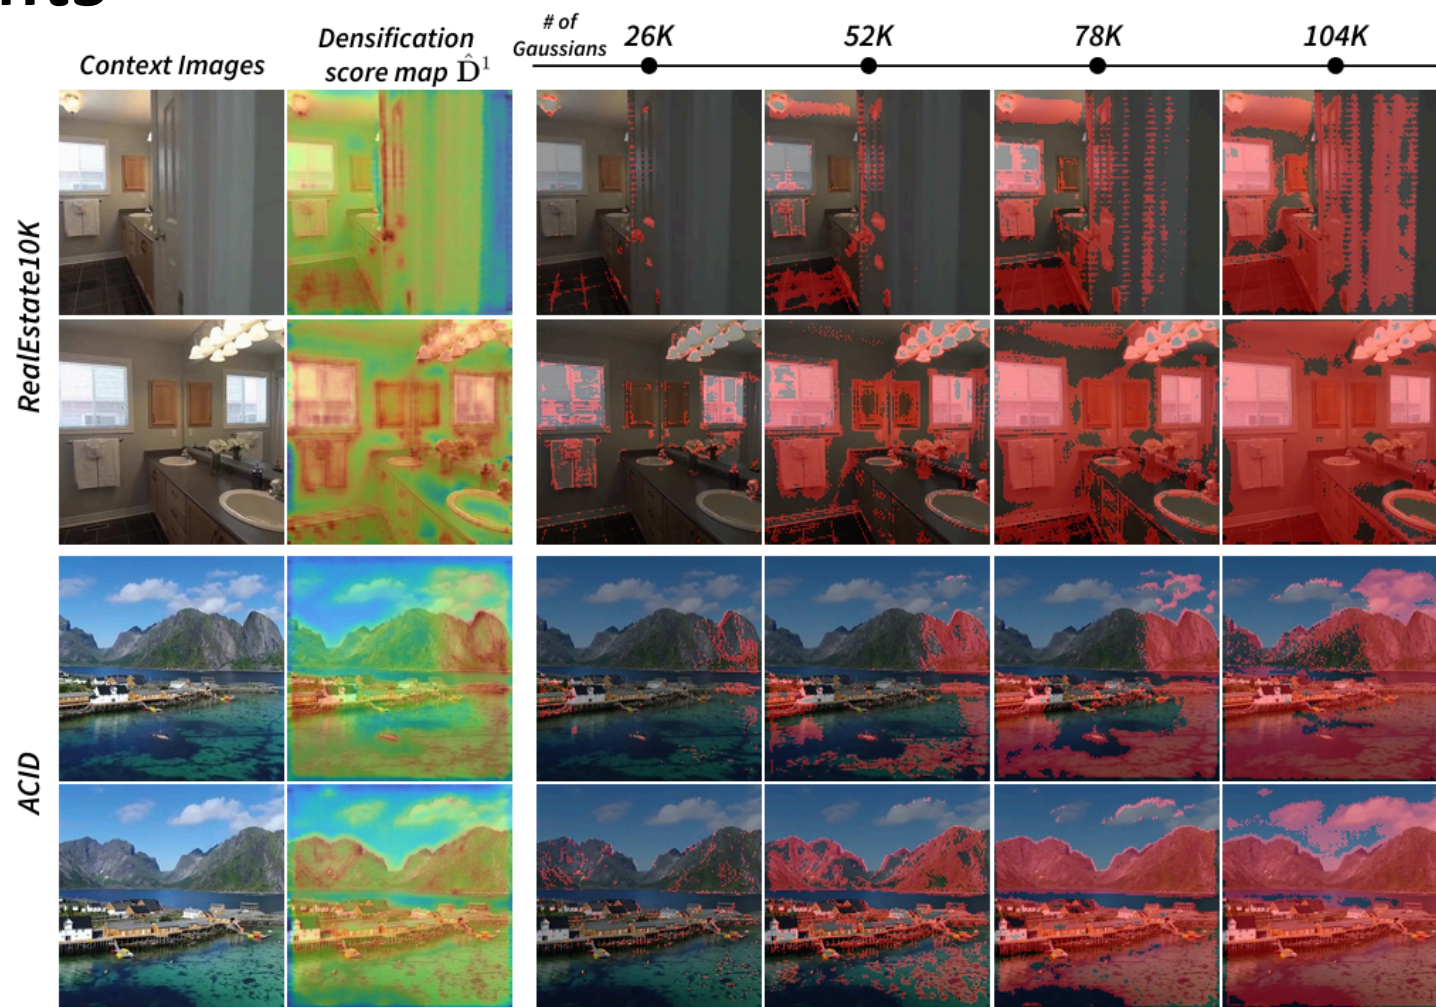


(a) Densification-score-guided allocation of F⁴Splat



(b) Rendering quality vs. Number of Gaussians

Experiments



Experiments

Table 1: Novel view synthesis performance on RE10K [65] under different numbers of input views. We report LPIPS/SSIM/PSNR for 8, 16, and 24 input views. Best and second-best results are highlighted in **bold** and underlined, respectively. τ^+ and τ^- denote the high- and low-threshold variants, respectively.

	Method	8 views				16 views				24 views			
		#GS↓	LPIPS↓	SSIM↑	PSNR↑	#GS↓	LPIPS↓	SSIM↑	PSNR↑	#GS↓	LPIPS↓	SSIM↑	PSNR↑
<i>Pose-Free</i>	NoPoSplat	524K	0.213	0.756	22.31	1049K	0.252	0.713	21.11	1573K	0.275	0.691	20.49
	VicaSplat	524K	0.241	0.713	21.18	1049K	0.384	0.596	17.56	1573K	0.443	0.546	16.13
	SPFSplat	524K	0.142	0.849	25.66	1049K	0.137	0.855	25.88	1573K	0.139	0.853	25.78
<i>Uncalibrated</i>	VicaSplat	524K	0.258	0.686	20.77	1049K	0.417	0.556	16.78	1573K	0.470	0.517	15.58
	AnySplat	<u>447K</u>	0.167	0.819	24.07	<u>820K</u>	0.148	0.842	25.10	<u>1142K</u>	0.143	0.849	25.40
	F⁴Splat_{τ^+}	105K	<u>0.142</u>	<u>0.847</u>	<u>25.26</u>	210K	<u>0.130</u>	<u>0.860</u>	<u>25.75</u>	315K	<u>0.128</u>	<u>0.862</u>	<u>25.85</u>
	F⁴Splat_{τ^-}	<u>447K</u>	0.131	0.859	25.64	<u>820K</u>	0.120	0.869	26.10	<u>1142K</u>	0.119	0.870	26.18

Table 2: Generalization to unseen datasets. Models are trained on RE10K [65] and evaluated on the unseen ACID dataset [33]. We compare reconstruction quality under different numbers of input views (8, 16, and 24).

	Method	8 views				16 views				24 views			
		#GS↓	LPIPS↓	SSIM↑	PSNR↑	#GS↓	LPIPS↓	SSIM↑	PSNR↑	#GS↓	LPIPS↓	SSIM↑	PSNR↑
<i>Pose-Free</i>	NoPoSplat	524K	0.268	0.672	22.84	1049K	0.294	0.644	22.14	1573K	0.307	0.630	21.78
	VicaSplat	524K	0.271	0.656	22.57	1049K	0.327	0.609	21.20	1573K	0.356	0.581	20.37
	SPFSplat	524K	0.215	0.736	24.89	1049K	0.214	0.743	25.07	1573K	0.218	0.744	25.00
<i>Uncalibrated</i>	VicaSplat	524K	0.315	0.588	21.31	1049K	0.377	0.547	19.82	1573K	0.399	0.529	19.22
	AnySplat	<u>481K</u>	0.248	0.696	23.30	<u>906K</u>	0.236	0.720	23.88	<u>1289K</u>	0.234	0.727	24.04
	F⁴Splat_{τ^+}	52K	<u>0.239</u>	<u>0.713</u>	<u>24.28</u>	105K	<u>0.230</u>	<u>0.726</u>	<u>24.54</u>	315K	<u>0.216</u>	<u>0.741</u>	<u>24.72</u>
	F⁴Splat_{τ^-}	<u>481K</u>	0.204	0.744	24.83	<u>906K</u>	0.201	0.753	25.01	<u>1289K</u>	0.203	0.752	24.88

Experiments

Table 3: Novel view synthesis performance comparison under 2-view setting. Results on ACID [33] dataset.

	Method	Average			
		#GS↓	LPIPS↓	SSIM↑	PSNR↑
<i>Pose-Required</i>	pixelNeRF	-	0.533	0.561	20.323
	pixelSplat	131K	0.195	0.779	25.819
	MVSplat	131K	0.196	0.773	25.512
<i>Pose-Free</i>	DUS3R	-	0.447	0.411	16.286
	MASt3R	-	0.461	0.409	16.179
	CoPoNeRF	-	0.406	0.606	20.950
	NoPoSplat	131K	0.189	0.781	25.961
	VicaSplat	131K	0.201	0.757	25.439
	SPFSplat	131K	0.176	0.807	26.796
<i>Uncalibrated</i>	VicaSplat	131K	0.218	0.726	24.548
	F⁴Splat_{τ+}	52K	0.188	0.784	26.028
	F⁴Splat_{τ-}	131K	0.176	0.794	26.282

Table 4: Ablation Studies. Experiments are conducted with 24 input views, where the Gaussian budget is fixed to 20% of the maximum number of Gaussians. (a)-(b) compare different Gaussian allocation strategies, (c) removes the level-wise Gaussian supervision during training, and (d) removes the scene-scale regularization term.

	Variant	LPIPS↓	SSIM↑	PSNR↑
(a)	Rand. based allocation	0.194	0.828	24.68
(b)	Freq. based allocation	0.160	0.841	25.36
(c)	w/o level-wise GS train	0.192	0.813	24.25
(d)	w/o scene scale reg.	0.712	0.006	4.82
(e)	Ours	0.143	0.854	25.47

Conclusion

- Feed-forward 3DGS의 기존 문제들을 다룬 논문
 - Optimization이 되지 않아 ADC를 사용할 수 없어서 densification의 한계를 극복
 - pixlwise gaussian initialization으로 의미없거나, 과도하게 생성되는 Gaussian을 억제
- Densification 단계에서 기존의 3DGS optimization의 효과와 novel view에서의 평가를 반영한 모델 학습
- Transformer 계열 SLAM에서 중요한 역할을 할 수 있을 듯