

RGS-SLAM: Robust Gaussian Splatting SLAM with One-Shot Dense Initialization

2026 (arXiv)

Wei-Tse Cheng, Yen-Jen Chiou, Yuan-Fu Yang*


National Yang Ming Chiao Tung University

2026.01.16

Contents

1. Introduction
2. Method
3. Experiments
4. Conclusion

Introduction



- 3D Gaussian Splatting(3DGS)의 발전으로 고품질 뷰 합성과 실시간 매핑이 가능
 - 하지만 대부분의 파이프라인은 여전히 잔차(residual)에 기반한 밀집화(densification)에 의존
 - 이는 오차가 감지될 때마다 Gaussian을 반복적으로 생성하거나 병합하는 방식
- 이 방식은 결국 최적화 하고자 하는 scene의 최종목표를 계속 바꾸는 것으로 이해할 수 있음
 - Gaussian이 계속 사라지거나, 추가되거나, 변형됨
- 그러면 처음부터 잘하자!
 - RGS-SLAM: Robust Gaussian Splatting SLAM with One-Shot Dense Initialization
 - 단일 프레임에서 고밀도 Gaussian을 초기화하여 SLAM의 견고성과 효율성을 향상

Introduction

- 즉, Keyframe에서 한번에 Gaussian을 생성
- 생성한 Gaussian은 꽤나 정확하다고 생각
 - Gaussian의 개수는 고정 후, 나머지 mean, covariance, color, opacity등은 최적화
 - MCMC....?
- 이 방식을 Monocular camera SLAM에 적용해보니 괜찮더라
 - 초기값이 정확하기 때문에 쓸만한 지도를 생성하는데까지 시간 단축
 - 당연히 pose 추정도 더 안정적
 - 기존 MonoGS 파이프라인에서, densification 단계만 feature matching으로 대체함

Method

RGS-SLAM pipeline

Method

1. Gaussian Splatting representaion

- Anisotropic Gaussian은 mean, covariance, color, opacity, 를 가짐

$$G = G_i, \quad G_i = \left(\mathbf{c}_i, \alpha_i, \boldsymbol{\mu}_i^W, \boldsymbol{\Sigma}_i^W \right), \quad \mathbf{c}_i \in \mathbb{R}^3, \alpha_i \in [0, 1], \boldsymbol{\mu}_i^W \in \mathbb{R}^3, \boldsymbol{\Sigma}_i^W \in \mathbb{R}^{3 \times 3}, \boldsymbol{\Sigma}_i^W \succ 0.$$

- 현재 카메라 pose(world-to-camera)

$$T_{WC} = [\mathbf{R} \mid \mathbf{t}]$$

- 3D Gaussian $\mathcal{N}(\boldsymbol{\mu}_i^W, \boldsymbol{\Sigma}_i^W)$ 를 투영하면 이미지 평면의 2D Gaussian을 얻음

$$\boldsymbol{\mu}_i^I = \pi(T_{WC} \boldsymbol{\mu}_i^W), \quad \boldsymbol{\Sigma}_i^I = \mathbf{J}_i \mathbf{R} \boldsymbol{\Sigma}_i^W \mathbf{R}^\top \mathbf{J}_i^\top$$

- 픽셀 p 의 색은 alpha blending으로 계산

$$C_p = \sum_{i \in \mathcal{N}(p)} \mathbf{c}_i \alpha_i \prod_{j=1}^{i-1} (1 - \alpha_j)$$

Method

2. Tracking and Camera Pose Optimization

- Objective per frame update
 - 매 이미지 frame마다 camera pose T_{WC} 를 추정
 - 렌더링된 이미지가 관측이미지(GT)와 최대한 비슷하도록 T_{WC} 를 업데이트
- 렌더링 이미지(예측)와 관측 이미지(GT)와의 Photometric error

$$E_{\text{pho}} = \|I(\mathcal{G}, T_{WC}) - \bar{I}\|_1$$

- 여기서, 기존의 방식처럼 photometric error를 그대로 쓰면 noise에 대응하기 어려움
 - affine brightness model을 도입하여 조명 변화에 대응
- 보정을 위한 gain과 bias 도입

$$(g_I, b_I) = \arg \min_{g, b} \sum_{x \in \Omega_I} \left(I(x) - g \hat{I}(x; \mathcal{G}, T_{WC}) - b \right)^2$$

Method

- 매 frame마다 gain과 bias를 도입해서 이미지 보정

$$\tilde{I}(x; \mathcal{G}, T_{WC}) = g_I \hat{I}(x; \mathcal{G}, T_{WC}) + b_I$$

- 다만, sequential한 이미지 특성상 rendered image와 observed image의 차이가 클 수 있음
 - 따라서, pixel마다 weight를 계산할 수 있도록 함

$$w_I(x) = w_\alpha(x) w_\nabla(x)$$

$$w_\alpha(x) = \text{clip}\left(\frac{\hat{\alpha}(x)}{\tau_\alpha}, 0, 1\right)$$

$$w_\nabla(x) = \text{clip}\left(\frac{\|\nabla I(x)\|_2}{\tau_\nabla}, 0, 1\right)$$

- 따라서, 최종 tracking loss는 다음과 같음

$$\mathcal{L}_{\text{track}}(T_{WC}) = \sum_{x \in \Omega_I} w_I(x) \|I(x) - \tilde{I}(x; \mathcal{G}, T_{WC})\|_1$$

Method

- Minimal Pose Jacobians on SE(3) for Pose update

$$T_{WC} \leftarrow \exp(\hat{\xi}) T_{WC}$$

- Pose $\xi \in \mathfrak{se}(3)$ 에 대한 mean/cov Jacobian
 - $[\cdot]_{\times}$: skew-symmetric matrix

$$\frac{\partial \mu^C}{\partial \xi} = [\mathbf{I} \quad -[\mu^C]_{\times}]$$

$$\frac{\partial \mu^I}{\partial \xi} = \mathbf{J}_{\pi}(\mu^C) [\mathbf{I} \quad -[\mu^C]_{\times}]$$

$$\frac{\partial \Sigma^I}{\partial \xi} = \frac{\partial \Sigma^I}{\partial \mathbf{J}} \frac{\partial \mathbf{J}}{\partial \mu^C} \frac{\partial \mu^C}{\partial \xi} + \frac{\partial \Sigma^I}{\partial \mathbf{R}} \frac{\partial \mathbf{R}}{\partial \xi}$$

- 즉, Pose refinement를 하면서 gaussian도 어떻게 움직이고, 어떻게 변형되어야 하는지 수학적으로 계산
 - analytic하게 구할 수 있기 때문에, 기존 autodiff방식들 overhead가 없음, 빠르다!

Method

3. Keyframe Scheduling by Co-Visibility

- 마지막으로 채택된 keyframe I_{k^*} 와 현재 frame I_k 의 **co-visibility**를 비교
- visible Gaussian 집합 $V(I)$ 를 정의 (screen-space opacity가 임계값을 넘는 Gaussian)

$$\text{IoU}(I_k, I_{k^*}) = \frac{|V(I_k) \cap V(I_{k^*})|}{|V(I_k) \cup V(I_{k^*})|}$$

- **Keyframe** 생성 조건: $\text{IoU}(I_k, I_{k^*}) < \tau$ 이고, inter-view parallax가 충분히 클 때
- 채택된 keyframe은 bounded buffer $\mathcal{B}$ 에 저장 $\rightarrow$ multi-view initialization에서 이웃(neighbors) 제공

Method

4. Dense Feature Matching

- **Dense correspondence**는 DINO v3로 추출한 feature 사용
 - viewpoint의 변화가 크거나, textureless 환경에서도 robust한 매칭 가능
- 를 위해, 현재 keyframe과 이웃한 K개의 keyframe을 선택
 - K개의 이웃 keyframe 집합 $\mathcal{N}_r$, 전체 Keyframe buffer $\mathcal{B}$

$$\mathcal{N}_r \subset \mathcal{B}$$

- 기준이 되는 image I_r 에서의 pixel이 이웃한 이미지 I_n 로의 변위벡터 $\mathbf{u}$ 를 구함
- 즉, 각 픽셀 p 는 다음과 같은 pair로 표현

$$(p, p + \mathbf{u}_{r \rightarrow n}(p))$$

Method

- 이 매칭된 포인트가 모두 정확하지는 않으니, epipolar test, blue-noise thinning 등의 후처리
 - Epipolar test로 outlier를 제거하고, blue-noise thinning으로 평면과 같이 굳이 dense한 매칭이 필요없는 부분에서의 포인트 수를 줄임
- 또한, 각 매칭된 feature에 대해 confidence score $\kappa_{r \rightarrow n}(p)$ 를 계산
 - 이웃한 image는 $\mathcal{N}_r$ 5장으로 고정, 전체 keyframe buffer $\mathcal{B}$ 는 최대 12개

$$\bar{\kappa}(p) = \frac{1}{|\mathcal{N}_r|} \sum_{n \in \mathcal{N}_r} \kappa_{r \rightarrow n}(p), \kappa_{r \rightarrow n}(p) \in [0, 1]$$

- **Multi-view triangulation**은 전통적인 DLT 알고리즘을 사용
 - view가 5개니, 그 중 small parallax, Large reprojection error를 갖는 view는 제외
 - 남은 view 중 reprojection error가 가장 낮은 view를 고르고, 비슷하다면 baseline이 큰 view를 선택

Method

Gaussian Initialization : Triangulation된 점을 **Surface-aligned Anisotropic Ellipsoid**로 초기화

- **Mean (μ_i^W)**: Multi-view Triangulation으로 구한 3D 좌표 $\hat{X}(p)$
- **Rotation (U_i)**: 주변 점들과의 Plane Fitting으로 법선($\mathbf{v}$) 추출 $\rightarrow$ Surface-aligned
 - plane fitting : 일정 반경(radius) 내의 이웃 점들로부터 centroid 구하고, Covariance matrix 구한 뒤 SVD 수행
 - $U_i = [\mathbf{t}_1, \mathbf{t}_2, \mathbf{v}]$ (Tangents + Normal)
- **Scale (Σ_i^W)**: back-projection된 2D Gaussian의 크기와 형태로부터 결정 (one-pixel image uncertainty)
 - $\Sigma_i^W = U_i \text{diag}(s_\perp^2, s_\perp^2, s_\parallel^2) U_i^\top$, where $s_\parallel > s_\perp$
 - $\Sigma^W = R \Sigma R^\top$
- **Color (c_i)**: 여러 View의 픽셀값 중 **Median** 사용 (Outlier 제거)
- **Opacity (α_i)**: 매칭 신뢰도($\bar{\kappa}$)를 기반으로 초기화 $\alpha_i \propto \bar{\kappa}(p)$

Method

5. Joint Mapping and Photometric Refinement

Insertion, Lightweight Merging, and Pruning

- 일단 initialization된 Gaussian들은 고정된 개수로 유지하는데, 추가는 안해도 삭제는 함
 - 관측 횟수가 너무 적거나($m_i < m_{\min}$), 가시성이 너무 안좋거나(view에 안들어오거나 가려지거나)($v_i < v_{\min}$),
 - 크기가 너무 커서 화면을 다 가리거나($\text{tr}(\Sigma_i^W) > \sigma_{\max}^2$), 너무 투명해서 거의 안보일 때 ($\alpha_i < \alpha_{\min}$)
 - 또는, 너무 겹치거나 비슷한 Gaussian은 merge

Sliding-Window Photometric Refinement

- Keyframe과 Gaussian 동시에 최적화

$$\mathcal{L} = \sum_{I \in \mathcal{W}} \lambda_{\text{pho}} \|g_I \mathcal{S}(\mathcal{G}, T_{WC}) + b_I - \bar{I}\|_1 + \mathcal{R}$$

- Regularizer를 추가했는데, needle이 되거나, 애매한 opacity 가진것들을 방지하고, 초기화된 위치에서 벗어나지 않도록

$$\mathcal{R} = \lambda_{\text{iso}} \sum_i \left\| \Sigma_i^W - \frac{\text{tr}(\Sigma_i^W)}{3} I_3 \right\|_F + \lambda_{\alpha} \sum_i \psi(\alpha_i) + \lambda_{\mu} \sum_i \|\mu_i^W - \bar{\mu}_i^W\|_2^2$$

Experiments

Hardware

- GPUs: $2 \times$ NVIDIA L40
- CPU: Intel Xeon Platinum 8362 @ 2.80 GHz (32 cores / 64 threads)
- System memory: 128 GB RAM or higher recommended
- Storage: At least 200 GB free disk space for datasets, checkpoints, and rendered results

Experiments

Table 1. Optimization time (min) on TUM RGB-D sequences *fr1/desk*, *fr2/xyz*, and *fr3/office*.

Method	<i>fr1/desk</i>	<i>fr2/xyz</i>	<i>fr3/office</i>	Avg.
MonoGS [11]	6.4	20.6	17.5	14.8
Ours (RGB)	4.9	16.1	15.0	12.0

Table 2. Camera tracking results on the Replica dataset under the RGB-D setting. Reported values denote RMSE of ATE across *room0–2* and *office0–4*.


Method	room0	room1	room2	office0	office1	office2	office3	office4	Avg.
iMAP [16]	3.12	2.54	2.31	1.69	1.03	3.99	4.05	1.93	2.58
NICE-SLAM [26]	0.97	1.31	1.07	0.88	1.00	1.06	1.10	1.13	1.07
Vox-Fusion [21]	1.37	4.70	1.47	8.48	2.04	2.58	1.11	2.94	3.09
ESLAM [6]	0.71	0.70	0.52	0.57	0.55	0.58	0.72	0.63	0.63
Point-SLAM [12]	0.61	0.41	0.37	0.38	0.48	0.54	0.69	0.72	0.53
MonoGS [11]	0.62	0.62	0.77	0.44	0.52	0.23	0.62	2.25	0.76
Ours (RGB)	0.45	0.51	0.53	0.52	0.78	1.03	0.45	0.63	0.61

Table 3. Camera tracking results on the TUM RGB-D dataset. Values denote RMSE of ATE over *fr1/desk*, *fr2/xyz*, and *fr3/office*.


Method	<i>fr1/desk</i>	<i>fr2/xyz</i>	<i>fr3/office</i>	Avg.
iMAP [16]	4.90	2.00	5.80	4.23
NICE-SLAM [26]	4.26	6.19	3.87	4.77
DI-Fusion [5]	4.40	2.00	5.80	4.07
Vox-Fusion [21]	3.52	1.49	26.01	10.34
ESLAM [6]	2.47	1.11	2.42	2.00
Co-SLAM [18]	2.40	1.70	2.40	2.17
Point-SLAM [12]	4.34	1.31	3.48	3.04
MonoGS [11]	1.50	1.44	1.49	1.47
Ours (RGB)	1.02	0.98	1.05	1.02

Experiments


Experiments



SplaTAM




iMAP




Vox-Fusion



Point-SLAM



MonoGS



Ours




Figure 3. Trajectory comparison on a living-room scene. The red line indicates the ground-truth path and the green line shows the estimated trajectory. Our method aligns more closely with the ground-truth and exhibits fewer large drifts than previous systems.

Experiments

Experiments

Table 5. Rendering quality results on the TUM RGB-D dataset.

Method (FPS)	Metric	fr1/desk	fr2/xyz	fr3/office	Avg.
Point-SLAM [12]	PSNR[dB]↑	13.79	17.62	18.29	16.57
	SSIM↑	0.625	0.710	0.749	0.695
	LPIPS↓	0.545	0.584	0.452	0.527
Photo-SLAM [4]	PSNR[dB]↑	20.97	21.07	19.59	20.54
	SSIM↑	0.740	0.730	0.690	0.720
	LPIPS↓	0.230	0.170	0.240	0.213
MonoGS [11]	PSNR[dB]↑	19.67	16.17	20.63	18.82
	SSIM↑	0.730	0.720	0.770	0.740
	LPIPS↓	0.330	0.310	0.340	0.327
GLORIE-SLAM [23]	PSNR[dB]↑	20.26	25.62	21.21	22.36
	SSIM↑	0.790	0.720	0.720	0.743
	LPIPS↓	0.310	0.090	0.320	0.240
SpliTAM [7]	PSNR[dB]↑	21.49	25.06	21.17	22.57
	SSIM↑	0.839	0.950	0.861	0.883
	LPIPS↓	0.255	0.099	0.221	0.192
RK-SLAM [10]	PSNR[dB]↑	22.31	22.47	20.67	21.82
	SSIM↑	0.741	0.729	0.710	0.727
	LPIPS↓	0.254	0.220	0.251	0.242
Ours (RGB)	PSNR[dB]↑	23.11	24.85	23.59	23.85
	SSIM↑	0.853	0.896	0.801	0.850
	LPIPS↓	0.232	0.198	0.219	0.216

Table 6. Reconstruction results on the Replica dataset. Lower is better for Acc./Comp., higher for Comp.Ratio.

Methods	Reconstruction		
	Acc. [cm] ↓	Comp. [cm] ↓	Comp.Ratio (%) ↑
iMAP [16]	3.624	4.934	80.515
NICE-SLAM [26]	2.373	2.645	91.137
Vox-Fusion [21]	1.882	2.563	90.936
Co-SLAM [18]	2.104	2.082	93.435
ESLAM [6]	2.082	1.754	96.427
SNI-SLAM [25]	1.942	1.702	96.624
Ours	1.537	1.477	97.843

Table 7. Impact of DFM on the TUM RGB-D dataset.

	Method	PSNR ↑	SSIM ↑	LPIPS ↓	RMSE ↓
fr1_desk	w/o DFM	19.67	0.73	0.33	1.5
	Ours	23.11	0.853	0.232	1.02
fr2_xyz	w/o DFM	16.17	0.72	0.31	1.44
	Ours	24.85	0.896	0.198	0.98
fr3_office	w/o DFM	20.63	0.77	0.34	1.49
	Ours	23.59	0.801	0.219	1.05

Conclusion

- RGS-SLAM: Robust Gaussian Splatting SLAM with One-Shot Dense Initialization
 - 단일 프레임에서 고밀도 Gaussian을 초기화하여 SLAM의 견고성과 효율성을 향상
- 기존의 residual 기반 densification 단계를 feature matching으로 대체
- feature는 DINO v3로 추출한 dense feature를 사용
 - DINO V3라서 가능한 방식이었던 것 같음
 - Real-time performance가 나올까?
- large-scale로 가져가려면 어떻게 해야할까?