

RMGS-SLAM: Real-time Multi-sensor Gaussian Splatting SLAM

2026 (arXiv)

Dongen Li¹, Yi Liu¹, Junqi Liu³, Zewen Sun¹, Zefan Huang^{1*}, Shuo Sun⁴, Jiahui Liu², Chengran Yuan¹,
Hongliang Guo³, Francis E.H. Tay¹, Marcelo H. Ang Jr.¹

¹ Advanced Robotics Centre, National University of Singapore

² School of Aeronautics and Astronautics, Shanghai Jiao Tong University

³ College of Computer Science, Sichuan University

⁴ Singapore-MIT Alliance for Research and Technology

Computer Vision and Robotics Lab

Minsu Kim

2026.04.30

Contents

1. Introduction
2. Method
3. Experiments
4. Conclusion

Introduction

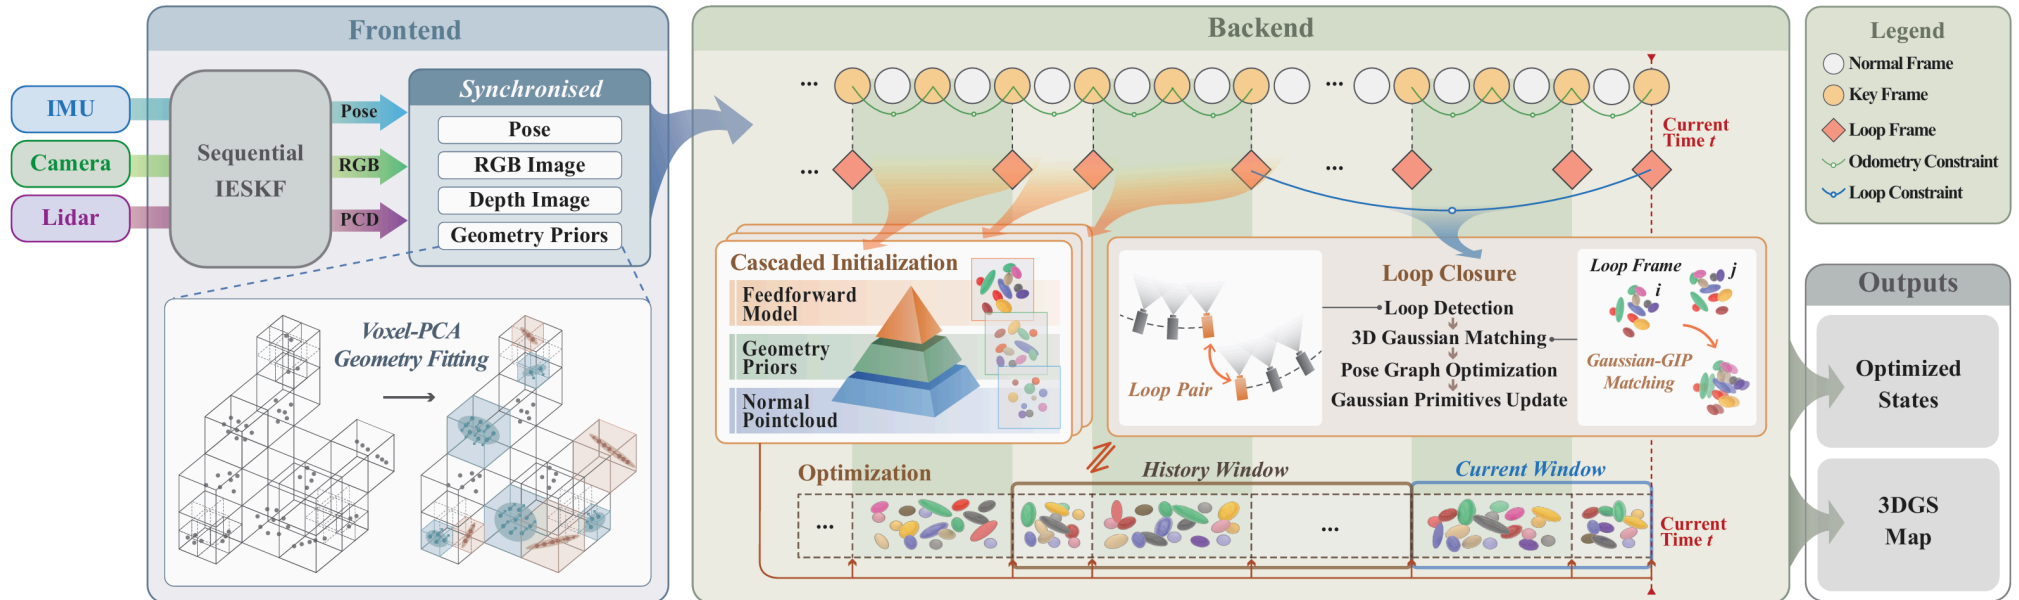
- SLAM...
- Point cloud를 넘어 scene을 더 디테일하게 표현하기 위해 3D Gaussian을 활용
- 다만, 이런 방식은 real-time SLAM에 부합하지 않음 왜?
 - 실시간 SLAM이라면, 1초에 최소한 10번씩 들어오는 센서 데이터를 처리하고 위치추정, 맵 업데이트를 해야하는데,,
 - 3DGS기반 SLAM은 그게 안됨 - Scene의 퀄리티를 높이려면, iterative optimization에 의존
 - SfM을 input으로 받는 3DGS는 gaussian만 최적화하면 되지만, SLAM은 **pose**도 최적화해야함
 - 최적화 할 state가 늘어남

Introduction

- 따라서, 본 논문에서는 Real-time Multi-sensor Gaussian Splatting SLAM (RMGS-SLAM)을 제안
 1. Explicit loop closure
 2. Cascaded Gaussian initialization with feed-forward predictions
 3. A new real-world benchmark
- Introduction이 워낙 짧아서 뭐로 real-time 달성하는지는 method에서...

Method

- Front-end는 FAST-LIO2 기반의 LIVO를 수행한 Fast-LIVO2
- Cascaded initialization, Gaussian을 활용한 large scale loop closure 전략 제안



Method

Voxel-PCA Geometry fitting

- 먼저, colored point cloud가 들어오면 hash-indexed voxel 로 나눔
- 각 voxel마다 PCA를 통해 mean μ , covariance $\mathbf{C}$ 계산 후, EVD로 고유 값, 벡터 추출

$$\lambda_{min} \leq \lambda_{mid} \leq \lambda_{max}, \quad \mathbf{v}_{min}, \mathbf{v}_{mid}, \mathbf{v}_{max}$$

- 고유값을 활용해서, voxel의 feature를 planar, line 으로 구분

if $\lambda_{min} < \tau_p$, **planar** with normal $\mathbf{v}_{min}$; if $\frac{\lambda_{max}}{\lambda_{min}} > \tau_l$, **linear** with direction $\mathbf{v}_{max}$; otherwise unreliable

- 위에서 구한 녀석들이 곧 Geometric descriptors $\mathbf{g}$ 로 활용됨 $\mathbf{v}_k \in \{\mathbf{v}_{min}, \mathbf{v}_{max}\}$

$$\mathbf{g} = [\mathbf{v}_k, \mu]^T \in \mathbb{R}^6, \mathbf{v}_k = \mathbf{v}_{min} \text{ for planar, } \mathbf{v}_k = \mathbf{v}_{max} \text{ for linear}$$

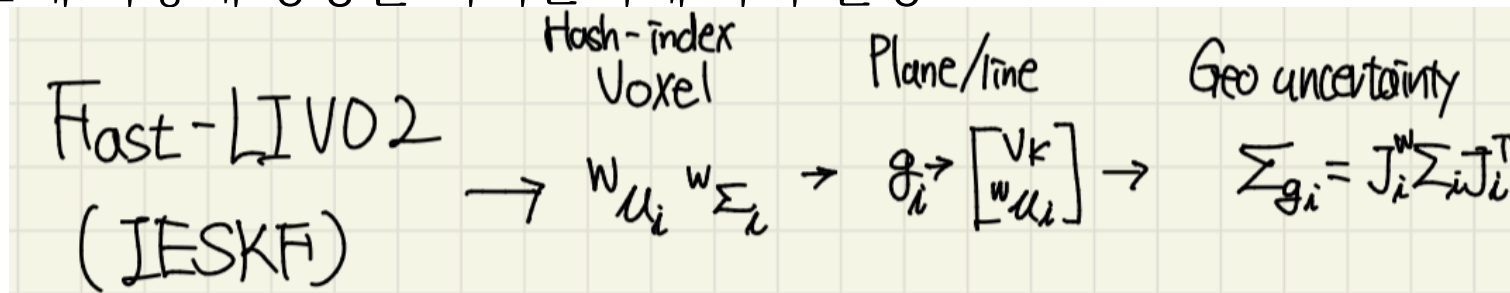
Method

- FAST-LIVO2로부터 넘어온 pose의 mean과 uncertainty를 이용해서, geometry descriptor의 covariance를 구함

$$\Sigma_g = \mathbf{J}_i \Sigma_i^W \mathbf{J}_i^\top$$

$$\mathbf{J}_i = \begin{bmatrix} \mathbf{V} \mathbf{F}_i \\ \frac{1}{N} \mathbf{I}_3 \end{bmatrix}, \quad \mathbf{F}_i = \begin{bmatrix} \mathbf{f}_i^{(min)} \\ \mathbf{f}_i^{(mid)} \\ \mathbf{f}_i^{(max)} \end{bmatrix}, \quad \mathbf{f}_i^{(m)} = \begin{cases} \frac{(\mathbf{p}_i^W - \boldsymbol{\mu})^\top}{N(\lambda_k - \lambda_m)} (\mathbf{v}_m \mathbf{v}_k^\top + \mathbf{v}_k \mathbf{v}_m^\top), & m \neq k, \\ \mathbf{0}, & m = k \end{cases}$$

- 즉, Geometry descriptor의 covariance는, 결국 pose의 covariance가 geometry descriptor에 어떻게 영향을 미치는지에 따라 결정



Method

- 그래서 Geometry fitting은 뭘 하고 싶은거냐...
- FAST-LIVO2로부터 얻은, 3D point를 가지고 만든 **Gaussian**에 **descriptor**를 붙이고 싶은 것
- 이 때, descriptor를 기준으로 mean, covariance를 다시 구함.
 - 이 과정을 통해 의미있는 voxel들만 남게 됨
 - line, plane을 제외한 unreliable한 voxel은 $\mathbf{g}$, $\Sigma_{\mathbf{g}}$ 자체가 없음
 - 최종적으로 살아남은 녀석들은 $\mathbf{g}_i = (\mathbf{p}_i^W, \mathbf{R}_{pca}, \mathbf{s}_{pca}, \mathbf{c}_i, m_i)$
- 결국 마지막의 $\Sigma_{\mathbf{g}}$ 의 trace만 씬
- Backend의 cascaded initialization과 loop closure에 활용

Method

Cascaded Gaussian Primitive Initialization

- 모든 frame에 대해서 gaussian을 만들 수 없으니, 일정 간격으로 keyframe을 선정하고, subset으로 **loop frame**을 가지고 있는데, 일정한 **평행, 회전이동 threshold**를 넘기면 loopframe으로도 선정
- 0번째, 1번째 사이의 loop frame들을 local segment로 분류
 - 새로운 loop frame이 들어오면, keyframe에서 관측된 colored point들을 모두 모으고, 일단 gaussian으로 initialize
 - 위치와 색상은 FAST-LIVO2로부터 얻은 결과를 사용하고, 나머지 Gaussian parameter는 아래와 같이 feed-forward prediction으로 구함

$$\Theta(p) = \begin{cases} \Theta_{\text{model}}(p), & \text{valid model prediction,} \\ \Theta_{\text{pca}}(p), & \text{invalid prediction} \wedge \text{geo-reliable,} \\ \Theta_{\text{heur}}(p), & \text{otherwise.} \end{cases}$$

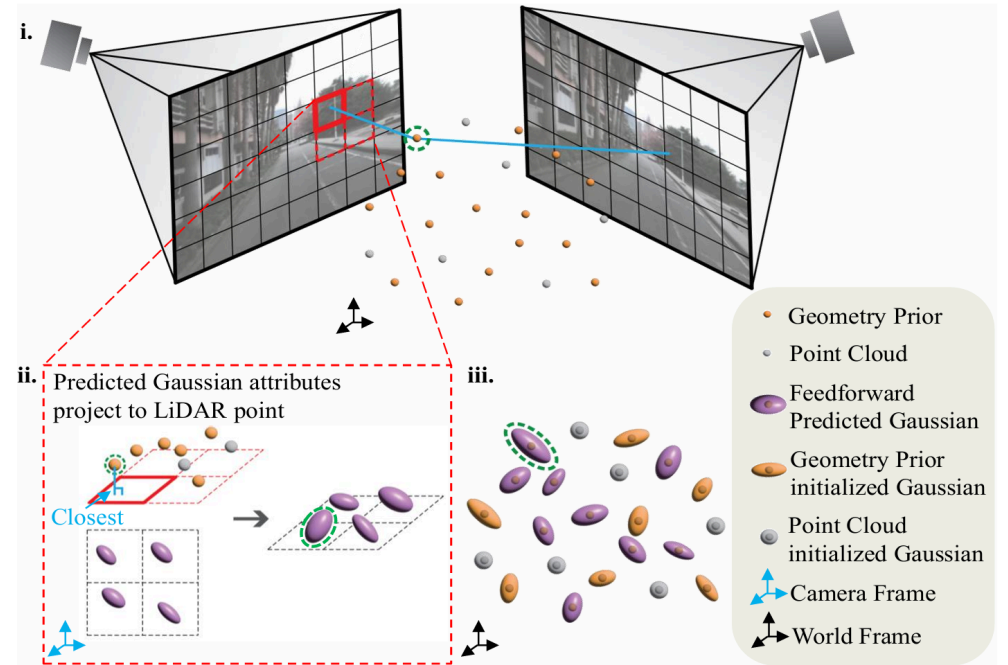
Method

- i) 에서는, 겹치든 안겹치든 가까운쪽으로 point 들을 projection하고, Gaussian을 일단 만듦
- 다만, 한 픽셀에 겹치는 point들도 있기 때문에, ii)에서는 카메라와 가장 가까운 점만 남기고 버림; Ghost 방지
- 픽셀 정중앙이 아닌 경우에, 주변의 4개 픽셀 예측 값을 bilinear interpolation해서 gaussian 속 성값 계산
 - FFM으로 만들어진 Gaussian을 정제하는 과정이 ii)
- 마지막 iii)에서는, Transformation을 곱해 camera frame에서 예측한 Gaussian을 world frame로 옮김
- 아래 수식을 통해서 Gaussian의 scale을 결정함

$$s_{out} = \log((d/f) \cdot \mathbf{a})$$

$$s_{out} = s_{out} + \log \beta$$

$$s_{out} = \log((d/f)$$



Method

Optimization

- 매 loop frame이 들어올 때 마다, gaussian은 계속 생성되고, map에 추가될텐데, 중복되는 녀석들은 제거할 필요가있음
 - 가장 가까운 Gaussian과 일정 거리 이하로 가깝거나, alpha값이 일정 threshold보다 낮아서 ghost가 될 가능성이 있어도 제거
- 두 개의 window를 사용하는데, history, current window로 나눔
 - Recent, History window에서 각각 랜덤하게 몇 장의 이미지를 뽑아옴
 - 뽑아온 이미지들 중에서, 아래와 같이 erode mask를 씌운 영역에 대해서만 최적화

$$\mathcal{M}_{\text{int}} = \text{Erode}(\mathcal{M}_{\text{geo}}, r_{\text{erode}})$$

$$\mathcal{L} = \lambda_{\text{rgb}} \mathcal{L}_{\text{rgb}} + \lambda_{\text{ssim}} \mathcal{L}_{\text{ssim}} + \lambda_{\text{depth}} \mathcal{L}_{\text{depth}}$$

Method

Gaussian-based Loop Closure

- Loop closure는 Global 3D Gaussian 맵을 활용해서 수행함
- Loop frame에 대해서, 현재 시간 대비 충분한 시간차이가 있으면서, geometric descriptor가 유사한 keyframe들을 loop candidate로 선정
 - 이 때, 신뢰성 있는 target gaussian set을 정하는 조건은 아래 식과 같음

$$\mathcal{G}_j^{\text{tar}} = \left\{ G_n \mid \exists k \in \mathcal{K}_j, \pi(\mathbf{p}_{c,n}^k) \in \Omega^k, \|\boldsymbol{\mu}_n - \mathbf{t}_w^k\|_2 < d_{\text{max}}, G_n \notin \mathcal{G}_i^{\text{src}} \right\}$$

- Point-to-plane residual을 활용하기 위해, 모든 Gaussian의 covariance를 surfel처럼 바꿈

$$\tilde{\Lambda} = \text{diag}(1, 1, 10^{-3})$$

Method

- 이렇게 만들고 난 뒤에, 신뢰할만한 Gaussian들을 기준으로, 현재 loop frame이 최적이어야 하는 $\mathbf{T}$ 를 찾아냄

$$\mathbf{r}_{mn}(\mathbf{T}) = \boldsymbol{\mu}_n^{\text{tar}} - \mathbf{T} \boldsymbol{\mu}_m^{\text{src}}$$

$$\boldsymbol{\Sigma}_{mn}(\mathbf{T}) = \tilde{\boldsymbol{\Sigma}}_n^{\text{tar}}$$

$$\mathbf{T}_{ij}^{\text{loop}} = \arg \min_{\mathbf{T} \in SE(3)} \sum_{(m,n) \in \mathcal{C}} \mathbf{r}_{mn}(\mathbf{T})^\top \boldsymbol{\Sigma}_{mn}(\mathbf{T})^{-1} \mathbf{r}_{mn}(\mathbf{T})$$

- 이후, GTSAM으로 PGO를 수행하면서, error propagation

Experiments

- Datasets
 - FAST-LIVO datasets
 - MARS-LVIG datasets
- Hardware
 - Livox Avia LiDAR
 - FLIR Blackfly S BFS-U3-51S5C
 - Xsense MTi-680G RTK GNSS/INS

Experiments




Fig. 3. Qualitative comparison of rendering results. The blue boxed region is enlarged and displayed in the corner for detailed visual inspection.

Experiments



TABLE I
RENDERING QUALITY AND RUNTIME EFFICIENCY COMPARISON ON SELECTED DATASETS.

Method	Metric	Lecture Center01	HKU Campus	Retail Street	CBD Building02	Driving1	Driving2	HKairport 03	HKisland 03
Gaussian-LIC2 [15]	PSNR↑	31.21	27.06	24.64	23.16	22.09	23.72	14.84	17.65
	SSIM↑	0.91	0.76	0.77	0.77	0.76	0.81	0.36	0.44
	LPIPS↓	0.17	0.21	0.76	0.23	0.28	0.22	0.59	0.54
	Real-time factor↓	1.14	1.09	1.05	1.17	1.08	2.14	∞	∞
GS-LIVM [16]	PSNR↑	21.48	12.06	17.34	13.57	16.17	14.86	×	2.96
	SSIM↑	0.75	0.42	0.51	0.51	0.55	0.56	×	0.16
	LPIPS↓	0.56	0.76	0.70	0.75	0.53	0.53	×	1.01
	Real-time factor↓	1.04	1.03	1.02	1.01	1.02	1.01	∞	1.01
MonoGS [9]	PSNR↑	30.22	30.12	25.53	23.04	23.79	22.17	16.55	13.87
	SSIM↑	0.91	0.84	0.81	0.74	0.76	0.72	0.38	0.37
	LPIPS↓	0.24	0.22	0.17	0.33	0.37	0.45	0.56	0.65
	Real-time factor↓	6.21	5.98	6.37	5.90	8.15	8.24	7.40	3.06
SplaTAM [10]	PSNR↑	25.23	20.57	20.84	11.89	9.93	9.64	13.16	11.96
	SSIM↑	0.81	0.65	0.66	0.32	0.31	0.29	0.29	0.23
	LPIPS↓	0.33	0.33	0.26	0.70	0.65	0.67	0.62	0.74
	Real-time factor↓	38.30	22.41	15.86	8.62	2.71	4.29	6.30	5.46
RMGS-SLAM (ours)	PSNR↑	35.63	30.85	28.44	27.64	21.79	22.20	19.64	19.55
	SSIM↑	0.95	0.88	0.91	0.93	0.80	0.82	0.54	0.67
	LPIPS↓	0.11	0.12	0.07	0.09	0.24	0.23	0.33	0.37
	Real-time factor↓	1.04	1.03	1.02	1.01	1.01	1.01	1.50	1.01

Experiments

TABLE II
POSE ACCURACY COMPARISON ON DIFFERENT DATASETS.

Method	Driving1	Driving2	HKairport03	HKisland03
FAST-LIVO2 [4]	3.55	2.86	1.41	2.74
Gaussian-LIC2 [15]	3.66	2.81	×	×
GS-LIVM [16]	4.86	2.95	×	65.26
MonoGS [9]	6.75	13.08	106.42	140.87
SplaTAM [10]	63.32	108.12	117.12	156.63
RMGS-SLAM (ours)	0.41	1.55	1.39	2.72



Experiments

TABLE III
ABLATION STUDY OF DIFFERENT COMPONENT CHOICES.

Variant	HKU Campus(small)			Driving1(large)		
	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
w/o voxel-PCA & FFM	27.53	0.82	0.15	19.57	0.73	0.30
w/o FFM	29.77	0.85	0.17	21.81	0.76	0.29
w/o voxel-PCA	27.98	0.81	0.16	20.76	0.75	0.27
w/ FFM (DepthSplat)	28.91	0.83	0.15	20.77	0.75	0.26
w/o loop closure	30.88	0.88	0.11	19.82	0.74	0.30
RMGS-SLAM (ours)	30.85	0.88	0.12	21.79	0.80	0.24

Conclusion

- 논문 제목과 달리, Backend optimization에 대한 새로운 기법 제안
 - SLAM 기준에서, Backend engineering 논문!
 - Front-end는 R3LIVE와 유사한 FAST-LIVO2를 사용
- FFM을 사용한 Gaussian param의 예측 뿐만아니라, 정확성을 높이기 위한 Geometric 한 정보도 활용
 - 전체적으로 Gaussian의 정제에 집중한 논문
- LiDAR를 사용하는 논문들은, LiDAR 범위 밖의 영역에 대해서 대부분 floats를 일으키는 문제
 - 쓸 만한 기법이라도..?